

Trabajo de Fin de Grado

Facultad de Economía y Empresa

TÍTULO: IMPACTO DE LA ADOPCIÓN DE LA INTELIGENCIA ARTIFICIAL EN LA ESTRUCTURA DEL EMPLEO EUROPEO (2023-2024): UN ANÁLISIS EMPÍRICO POR SECTORES Y OCUPACIONES

AUTOR/A: *Eduardo Fernández Dionicio*

TUTOR/A: *Javier Fernández-Blanco*

GRADO: *Economía*

FECHA: *27 de mayo de 2025*

RESUMEN Y PALABRAS CLAVE

Este trabajo analiza empíricamente el impacto de la adopción de la inteligencia artificial (IA) en la estructura del empleo en Europa durante 2023-2024, con un enfoque desagregado por sectores económicos y por ocupaciones. A partir de datos de Eurostat de reciente disponibilidad, se construye un panel de datos para múltiples países europeos, integrando información sobre la proporción de empresas que utilizan IA y la distribución del empleo por sectores (NACE Rev.2) y ocupaciones (ISCO-08). Mediante modelos econométricos de datos de panel con efectos fijos, se examina si una mayor adopción empresarial de IA se asocia a cambios en la participación relativa del empleo en distintos sectores y categorías ocupacionales.

Los resultados indican que la adopción de IA tiene efectos heterogéneos, donde se observa un aumento relativo del empleo en sectores intensivos en conocimiento (por ejemplo, servicios profesionales y tecnológicos) y disminuciones en sectores de baja cualificación o con tareas rutinarias (como comercio o transporte). De forma similar, a nivel ocupacional, las ocupaciones de alta cualificación, intensivas en tareas cognitivas avanzadas, aumentan su peso relativo en el empleo bajo mayores niveles de adopción de IA, mientras que las ocupaciones de menor cualificación o más rutinarias tienden a reducir su participación relativa. Estas tendencias sugieren que, en el contexto europeo reciente, la IA podría estar actuando más como un complemento al trabajo cualificado y un sustituto parcial en puestos rutinarios. No obstante, el análisis econométrico formal utilizando un índice de intensidad rutinaria no encuentra una evidencia concluyente de efectos diferenciales según el contenido de tareas, probablemente debido al corto horizonte temporal considerado, mientras que el análisis econométrico desagregado por sub-tareas mostró una asociación de complementariedad en tareas manuales rutinarias, contradiciendo las teorías clásicas. En conjunto, el estudio aporta evidencia inicial sobre cómo la irrupción de la IA reconfigura la estructura del empleo, y se discuten implicaciones de política orientadas a facilitar la adaptación de la fuerza laboral a esta transición tecnológica.

Palabras clave: Inteligencia artificial, mercado laboral, automatización, empleo europeo, adopción tecnológica, tareas rutinarias, cualificación laboral, estructura laboral

ÍNDICE

1. INTRODUCCIÓN.....	1
2. REVISIÓN DE LITERATURA Y MARCO TEÓRICO.....	3
2.1. El impacto de la IA y la automatización en el empleo.....	3
2.2. Teoría de tareas rutinarias y no rutinarias	3
2.3. Evidencia empírica reciente sobre IA y empleo	4
2.4. Vacíos de investigación y motivación del presente estudio	5
3. DATOS Y METODOLOGÍA.....	7
3.1. Modelo sectorial (clasificación NACE Rev. 2)	8
3.2. Modelo ocupacional (clasificación ISCO-08).....	8
3.3. Comentario metodológico final	9
4. ANÁLISIS DESCRIPTIVO DE LA ADOPCIÓN DE IA Y EL EMPLEO	11
5. RESULTADOS ECONOMETRICOS.....	15
5.1. Resultados sectoriales.....	15
5.2. Resultados ocupacionales	18
5.3. Conclusiones de los resultados econométricos.....	20
6. MODELOS MACROECONÓMICO.....	22
6.1. Modelo teórico de tareas no rutinarias vs rutinarias.....	22
6.2. Resultados del modelo teórico de tareas no rutinarias vs rutinarias	24
6.3. Modelo teórico de sub-tareas.....	25
6.4. Resultados del modelo teórico de sub-tareas	26
6.5. Conclusiones de los modelos teóricos (RTI y sub-tareas)	28
7. PRUEBAS DE ROBUSTEZ.....	29
8. DISCUSIÓN DE RESULTADOS E IMPLICACIONES.....	30
8.1. Contraste con la teoría	30
8.2. Implicaciones sectoriales y de política	30
9. CONCLUSIONES Y LIMITACIONES	32
9.1. Síntesis de hallazgos principales	32
9.2. Limitaciones del estudio	33
9.3. Agenda de investigación futura	34
REFERENCIAS	35
ANEXO	37

1. INTRODUCCIÓN

La rápida irrupción de la inteligencia artificial (IA) en la economía contemporánea ha creado incertidumbre sobre el futuro del mercado laboral ante el progreso tecnológico. Históricamente, la automatización tuvo un efecto sustitución heterogéneo en el empleo, dependiendo del tipo de tareas susceptibles de ser reemplazadas por maquinaria. No obstante, el progreso tecnológico conllevó también a la creación de nuevas tareas, aumentando la demanda de trabajo en otras áreas y provocando desplazamientos estructurales en la estructura del empleo, evitando un desempleo masivo permanente. Surge entonces la pregunta: ¿Seguirá la inteligencia artificial un patrón similar al de los avances tecnológicos del pasado?

En los últimos años, han emergido nuevos avances en tecnologías relacionadas con la IA, caracterizadas por sus capacidades cognitivas avanzadas, como el aprendizaje basado en datos (Machine Learning) y las redes neuronales profundas (Deep Learning). El foco actual está en la última tendencia en tecnología, la IA Generativa, rama de la IA enfocada en la creación de contenido original (texto, imágenes, etc.) a partir de datos existentes mediante modelos de aprendizaje profundo. El impacto de la nueva generación de IA en el corto y largo plazo es un tema de debate actual, pues se anticipa un efecto significativo no solo a nivel macroeconómico, sino también a nivel individual.

En este contexto, el objetivo principal de este Trabajo de Fin de Grado es analizar empíricamente cómo la adopción de tecnologías de IA por parte de las empresas está afectando la estructura del empleo en Europa en los años recientes. En particular, se estudiará este impacto diferenciando por ramas de actividad económica (clasificación NACE Rev. 2) y por grupos ocupacionales (clasificación ISCO-08) durante 2023 y 2024. De este modo, el trabajo explora la heterogeneidad del impacto de la IA a diferentes niveles, algo aún poco abordado en la literatura.

Se plantea la hipótesis principal de que la adopción de IA tendrá un efecto heterogéneo sobre el empleo según el tipo de tareas predominantes. En concreto, inspirándonos en el marco teórico de las tareas rutinarias vs. no rutinarias, se espera que en los sectores intensivos en tareas rutinarias (mecánicas o repetitivas) la difusión de la IA se asocie con reducciones en la participación de estos sectores en el empleo total (indicando posibles efectos de sustitución tecnológica). Por el contrario, en los sectores intensivos en tareas no rutinarias (que suelen requerir habilidades cognitivas o creativas avanzadas) la IA actuaría más como complemento al trabajo humano, esperándose una mayor participación del empleo en dichos sectores bajo altos niveles de adopción de IA. Asimismo, se anticipa un patrón similar a nivel ocupacional, donde ocupaciones altamente cualificadas (intensivas en tareas no rutinarias, cognitivas) podrían beneficiarse o resistir mejor la automatización por IA, mientras que las ocupaciones de baja cualificación o intensivas en tareas rutinarias serían las más susceptibles a experimentar desplazamientos o pérdida de peso relativo.

Para contrastar esta hipótesis, el estudio emplea modelos econométricos de datos de panel con efectos fijos por país-sector (o país-grupo ocupacional) y año, utilizando indicadores de

adopción de IA a nivel sectorial y midiendo la evolución de la composición del empleo. En términos metodológicos, se controla por factores macroeconómicos relevantes, como el PIB per cápita, el nivel educativo de la fuerza laboral o la tasa de desempleo, a fin de aislar, hasta donde es posible con datos agregados, la asociación específica entre la difusión de la IA y la estructura del empleo.

La estructura del presente trabajo es la siguiente: en la Sección 2 se presenta una revisión exhaustiva de la literatura existente y se identifican vacíos relevantes en la investigación. En la Sección 3 se describen detalladamente los datos utilizados y la metodología econométrica empleada. La Sección 4 ofrece un análisis descriptivo preliminar de los datos que anticipa los principales patrones observados. Los resultados principales del análisis econométrico se presentan y discuten en la Sección 5, mientras que en la Sección 6 se evalúa el encaje de estos hallazgos con modelos macroeconómicos estándar. Las pruebas adicionales para verificar la robustez de los resultados se detallan en la Sección 7. La Sección 8 proporciona una discusión integral de las implicaciones económicas y políticas, y finalmente, en la Sección 9, se ofrecen conclusiones generales, se identifican limitaciones del estudio, y se sugieren líneas futuras de investigación.

2. REVISIÓN DE LITERATURA Y MARCO TEÓRICO

2.1. El impacto de la IA y la automatización en el empleo

La creciente adopción de la inteligencia artificial y las tecnologías de automatización han generado un intenso debate en torno a su impacto en el mercado laboral. La literatura muestra posiciones diversas acerca de si estas tecnologías destruyen o crean empleo, destacando tanto efectos negativos como positivos según tareas y contextos.

Frey y Osborne (2013) analizaron la vulnerabilidad de distintas ocupaciones ante la automatización y estimaron que alrededor del 47 % de los empleos en Estados Unidos corrían un alto riesgo de ser automatizados en las próximas décadas, especialmente aquellos asociados a tareas rutinarias y repetitivas. Este estudio se convirtió en un referente para identificar los perfiles laborales más expuestos a las tecnologías avanzadas.

Acemoglu y Restrepo (2020) evaluaron empíricamente la introducción de robots industriales en el mercado laboral estadounidense. Sus resultados mostraron que, por cada robot adicional por mil trabajadores, la tasa de empleo desciende y los salarios medios se reducen, evidenciando efectos desplazadores de la automatización en determinadas regiones y sectores manufactureros.

Por otra parte, la Organización para la Cooperación y el Desarrollo Económicos (OCDE, 2019) subraya que el impacto neto de la automatización depende en gran medida de la capacidad de los trabajadores y de los sistemas formativos para adaptarse. El informe destaca que la inversión en capacitación y reciclaje profesional es crucial para que la fuerza laboral transite hacia los nuevos puestos que emergen en la economía digital.

Por tanto, los estudios señalan que la IA y la automatización ejercen un efecto significativo sobre el empleo, pero la magnitud y dirección de dicho efecto varían según el tipo de tareas desempeñadas y la respuesta institucional en materia de formación. En los apartados siguientes se parte de este debate y se analiza cómo la teoría de tareas rutinarias y no rutinarias explica estos efectos heterogéneos en la estructura del empleo.

2.2. Teoría de tareas rutinarias y no rutinarias

La teoría de las tareas rutinarias y no rutinarias dice que el impacto de las nuevas tecnologías varía según la naturaleza de las tareas laborales. En términos generales, las tareas rutinarias (aquellas repetitivas, predecibles y codificables) son muy susceptibles de ser automatizadas, mientras que las tareas no rutinarias (que requieren pensamiento creativo, resolución de problemas complejos o interacción interpersonal) tienden a ser complementadas por la tecnología en lugar de sustituidas.

Autor, Levy y Murnane (2003) formalizaron este marco teórico al demostrar que la informatización estuvo asociada a una menor demanda de trabajo en tareas rutinarias (manuales y cognitivas) y a un aumento en la demanda de trabajo en tareas no rutinarias de carácter cognitivo. En otras palabras, las computadoras sustituyen actividades rutinarias

repetitivas, pero potencian la productividad de los trabajadores en tareas no rutinarias complejas.

Este enfoque centrado en el tipo de tareas ha sido fundamental para explicar la polarización del empleo observada en las últimas décadas. Por ejemplo, Autor y Dorn (2013) documentaron en Estados Unidos una disminución de los empleos de calificación media intensivos en tareas rutinarias, acompañado por un crecimiento relativo de ocupaciones en los extremos alto y bajo de la distribución de habilidades, es decir, aumentaron los puestos no rutinarios cognitivos (profesionales, técnicos) y también ciertos empleos no rutinarios manuales de servicios, mientras que los trabajos rutinarios administrativos o manufactureros se contrajeron. Estudios europeos obtuvieron patrones similares de desplazamiento laboral desde ocupaciones rutinarias hacia ocupaciones no rutinarias en servicios y sectores del conocimiento (Goos, Manning & Salomons, 2014).

A efectos analíticos, se han desarrollado métricas para cuantificar el contenido rutinario de cada ocupación. Destaca el índice de Intensidad de Tareas Rutinarias (RTI), el cual sintetiza qué fracción de las tareas de una ocupación son de carácter rutinario. Valores elevados de RTI indican ocupaciones altamente automatizables, mientras que valores bajos reflejan una proporción mayor de tareas no rutinarias. Además, estudios recientes como el de Mihaylov y Tijdens (2019), construyen índices de contenido rutinario y no rutinario para 427 ocupaciones detalladas (a 4 dígitos, ISCO-08), proporcionando una base empírica para comparar cómo distintas ocupaciones podrían ser afectadas por la automatización.

En resumen, la teoría de tareas rutinarias y no rutinarias ofrece un respaldo conceptual para entender los efectos heterogéneos del progreso tecnológico, donde se anticipa una sustitución del trabajo humano en tareas rutinarias y una complementación en tareas no rutinarias, teorías que serán puesta a prueba en apartados posteriores.

2.3. Evidencia empírica reciente sobre IA y empleo

La evidencia empírica acerca del impacto de la IA en el empleo es aún incierta y con resultados mixtos, dependiendo del contexto geográfico y del enfoque metodológico. En el caso de Europa, estudios recientes sugieren efectos hasta ahora positivos o de complementariedad en ocupaciones de alta cualificación. Por ejemplo, un análisis en 16 países europeos realizado por Albanesi et al. (2023) identificó que las ocupaciones con mayor exposición a tecnologías de IA han aumentado su participación en el empleo total. Este incremento se observó particularmente en ocupaciones caracterizadas por una fuerza laboral más joven y con alto nivel educativo, lo cual indica que la adopción de IA ha tendido a complementar a trabajadores cualificados en lugar de sustituirlos. Por tanto, hasta 2022 la IA en Europa se asoció con mayor demanda de trabajo en ocupaciones intensivas en conocimiento.

En contraste, la evidencia proveniente de Estados Unidos sugiere que la IA puede tener efectos disruptivos en empleos de menores habilidades. Un estudio de Bonfiglioli et al. (2023) analizó la difusión temprana de la IA en las zonas laborales de EE. UU. (commuting zones) durante 2000-2020. Sus resultados indicaron que la adopción de IA estuvo asociada a una reducción neta del empleo, excepto en las ocupaciones mejor remuneradas o aquellas que

requieren formación STEM (Ciencia, Tecnología, Ingeniería y Matemáticas), en otras palabras, en las regiones más expuestas a la IA, el empleo disminuyó en términos agregados, salvo en los puestos altamente cualificados, que habrían resistido o incluso prosperado. Estos hallazgos sugieren que, al menos en la fase inicial analizada, la IA actuó principalmente como un sustituto de la mano de obra en muchas ocupaciones, mitigando su impacto negativo solo en los roles de alta especialización.

Más allá de estos estudios concretos, las estimaciones sobre IA y empleo varían según el enfoque. Algunas investigaciones y voces influyentes resaltan las oportunidades que la IA crea. Por ejemplo, Brynjolfsson et al. (2018) argumentan que la IA puede aumentar la productividad de los trabajadores encargándose de tareas rutinarias, lo que libera a los empleados para concentrarse en funciones de mayor valor añadido. En esta línea optimista, se ha estimado que la IA generará tantos empleos nuevos (en áreas de desarrollo, mantenimiento y uso de estas tecnologías) como los que pudiera desplazar. Por el contrario, otros expertos destacan los riesgos, donde Acemoglu (2022) advierte que, si no se implementan políticas adecuadas, las empresas podrían utilizar la IA principalmente para automatizar procesos en lugar de complementarlos, reduciendo la demanda de trabajadores. De modo similar, Acemoglu y Johnson (2023) subrayan que los beneficios de la IA podrían concentrarse en ciertas élites económicas si no se encauza su desarrollo hacia mejoras generalizadas en productividad compartida.

En síntesis, la evidencia reciente sugiere que el impacto de la IA en el empleo no es uniforme, sino que depende del tipo de tareas que predominen en cada sector u ocupación, así como del contexto institucional y temporal analizado. En Europa, por ahora, predominan indicios de que la IA complementa a trabajadores cualificados (en lugar de destruir masivamente empleos), mientras que en otros entornos y segmentos laborales se han detectado efectos sustitutivos. Esta diversidad de resultados enfatiza continuar investigando la relación IA-empleo con distintos enfoques y datos más actuales, para entender en qué condiciones la IA actúa como complemento o sustituto del trabajo humano.

2.4. Vacíos de investigación y motivación del presente estudio

Pese al creciente número de estudios sobre la IA y la automatización, existen vacíos de investigación en la comprensión de sus efectos laborales, lo que motiva directamente el presente trabajo.

En primer lugar, gran parte de la literatura hasta la fecha se ha basado en proyecciones teóricas o análisis de oleadas tecnológicas previas (robots industriales, computarización de los 2000) más que en datos empíricos de la actual generación de IA. Esto deja incierto si la IA moderna, especialmente la IA generativa surgida en 2022-2023, seguirá el mismo patrón que tecnologías anteriores. De hecho, aunque la experiencia histórica sugiere que los temores de desempleo tecnológico suelen ser exageradas (las innovaciones pasadas acabaron generando nuevas oportunidades), sigue siendo una incógnita si la IA adoptará este patrón o, por el contrario, podría tener efectos sin precedentes en el mercado laboral.

Un vacío específico proviene de la falta de datos recientes sobre la adopción de IA. Muchos estudios se apoyaron en indicadores indirectos (como número de patentes de IA, evaluaciones de expertos sobre qué tareas puede hacer la IA) en lugar de datos observados de uso de IA en empresas. Esto significa que no sabemos con certeza cómo la adopción real de IA por las empresas está afectando, en tiempo presente, a distintos sectores y ocupaciones.

Otro vacío se relaciona con la identificación causal y la heterogeneidad de contexto. Dado que la adopción de IA suele correlacionar con otras tendencias (por ejemplo, la transformación digital general de una empresa o país), es difícil aislar el efecto propio de la IA sobre el empleo. Muchos estudios macro afrontan desafíos para distinguir correlación de causalidad y son necesarias aproximaciones más detalladas, algo que los datos agregados no permiten fácilmente. Además, la mayor parte de la evidencia disponible proviene de EE. UU. u otros entornos, mientras que Europa presenta instituciones laborales y estructuras sectoriales diferentes que podrían moderar el impacto de la IA. Esto sugiere la importancia de estudiar el caso europeo con datos propios, en lugar de extrapolar conclusiones foráneas.

La motivación de este Trabajo Fin de Grado radica en contribuir a llenar estos vacíos. Aprovechando datos europeos muy recientes (2023-2024), el estudio ofrece una de las primeras evaluaciones empíricas sobre cómo la adopción de IA se relaciona con la distribución del empleo por sectores y ocupaciones en Europa. A diferencia de análisis previos, que suelen ser prospectivos o de periodos anteriores, esta investigación observa directamente la fase inicial de difusión de la IA generativa y otras tecnologías de IA en las empresas. Asimismo, al desagregar por ramas de actividad y grupos ocupacionales, el estudio explora la heterogeneidad del impacto de una forma poco abordada hasta ahora en la literatura. Con ello, este trabajo pretende aportar evidencia objetiva al debate, informando si en el contexto europeo reciente la IA asocia más un rol de complemento al trabajo humano o de sustitución, y sentando bases para investigaciones futuras más profundas.

3. DATOS Y METODOLOGÍA

Para responder nuestra pregunta de investigación, se construyó una base de datos de panel combinando información proveniente de Eurostat para 29 países europeos¹ durante los años 2023-2024.

La variable independiente principal es la adopción de Inteligencia Artificial (IA) por parte de las empresas. Esta información procede de la encuesta anual de Eurostat sobre el uso de tecnologías de la información y la comunicación (TIC) en empresas (Digital Economy and Society), que ofrece datos basados en muestras independientes seleccionadas mediante muestreo aleatorio estratificado para cada año y país. A partir de esta fuente, se emplearon indicadores² relativos al porcentaje de empresas que declaran utilizar alguna tecnología de IA, diferenciados según actividad económica, país y año. Para nuestro análisis, agregamos estos datos al nivel sector-país-año dentro de la variable `IA_Adoption`, definida como el porcentaje de empresas de cada sector, país y año que utiliza tecnologías basadas en IA.

La variable dependiente se define como la participación relativa del empleo en cada sector económico (clasificación NACE Rev. 2³) y grupo ocupacional (clasificación ISCO-08⁴). Estos datos provienen de la Encuesta de Población Activa (EU-LFS) recopilada por Eurostat.

En el modelo sectorial, la variable dependiente es la proporción del empleo total en cada sector económico denominada `Share_Sector`, según la clasificación NACE Rev.2. En el modelo ocupacional, la variable dependiente corresponde a la proporción del empleo en cada grupo ocupacional dentro de cada sector económico y denominada `Share_Occupation`, de acuerdo con la clasificación ISCO-08. Estas proporciones se obtuvieron mediante tablas agregadas proporcionadas por Eurostat, que permiten comparar de forma consistente el peso relativo de cada sector y ocupación, eliminando distorsiones derivadas del tamaño económico diferencial entre países.

Para aislar en la medida de lo posible la asociación entre la adopción de IA y la estructura agregada del empleo, se introdujeron variables macroeconómicas relevantes extraídas también de Eurostat, agregadas por país y año:

- PIB real per cápita (`GDPCap`): PIB ajustado por paridad de poder adquisitivo, incluido para controlar diferencias en el ciclo económico o nivel de desarrollo entre países.
- Nivel educativo (`Educ_Rate`): Proporción de personas empleadas entre 25 y 64 años con educación terciaria (ISCED 2011), para capturar diferencias en la estructura educativa de los países.
- Tasa de paro (`Unemp_Rate`): Porcentaje de la población activa desempleada, que controla diferencias estructurales del mercado laboral.

¹ Tabla A14 (Anexo). Listado completo de países y número de observaciones por país

² Tabla A6 (Anexo). Indicadores de adopción de IA: códigos Eurostat y descripción

³ Tabla A15 (Anexo). Clasificación NACE Rev.2 detallada a 1 dígito

⁴ Tabla A5 (Anexo). Clasificación ISCO-08 detallada por grupos principales (0C0-0C9)

La metodología econométrica utilizada son modelos de datos de panel con efectos fijos por país y año, estimados mediante Mínimos Cuadrados Ordinarios (MCO). Con esta especificación, cada país tiene un término constante propio (efecto fijo país), y cada año tiene también un efecto fijo temporal. Esto permite controlar características inobservables constantes de cada país (factores institucionales, culturales o estructurales) y shocks temporales comunes a todos los países. Así, los resultados reflejan únicamente variaciones intra-país en la adopción sectorial de IA y su asociación con la estructura agregada del empleo.

Adicionalmente, para corregir problemas potenciales de heterocedasticidad y autocorrelación, se utilizaron errores estándar robustos clusterizados por país en el modelo sectorial y por país–sector–año en el modelo ocupacional, pues las diez ocupaciones dentro de cada célula comparten la misma exposición a IA y las mismas condiciones macro. Esto produce errores estándar robustos garantizando inferencias estadísticas válidas.

3.1. Modelo sectorial (clasificación NACE Rev. 2)

El primer modelo estima el efecto sectorial de la adopción de IA sobre la participación relativa del empleo:

$$Share_Sector_{i,s,t} = \beta_0 + \beta_1 \times IA_Adoption_{i,s,t} + \beta_2 \times GDPCap_{i,t} + \beta_3 \times Educ_Rate_{i,t} + \beta_4 \times Unemp_Rate_{i,t} + \sum_{s \neq M} \gamma_s [Sector_s \times IA_Adoption_{i,s,t}] + \mu_i + \lambda_t + \varepsilon_{i,s,t}$$

Donde:

- i = país
- s = sector económico (clasificación NACE Rev. 2; la sección M se toma como categoría base, por eso el sumatorio excluye $s=M$)
- t = año
- μ_i = efectos fijos de país
- λ_t = efectos fijos de tiempo
- $\varepsilon_{i,s,t}$ = término de error idiosincrático

Este modelo incorpora interacciones entre la adopción de IA ($IA_Adoption$) y los sectores económicos según la clasificación NACE Rev. 2, tomando como base el sector M (actividades profesionales, científicas y técnicas). El coeficiente β_1 indica el efecto promedio de la adopción de IA sobre la participación del empleo en este sector base, mientras que los coeficientes γ_s indican los efectos diferenciales de la IA en otros sectores respecto a la categoría base.

3.2. Modelo ocupacional (clasificación ISCO-08)

El segundo modelo estima cómo varía la composición ocupacional del empleo entre sectores con diferentes niveles de adopción de IA. La especificación econométrica es la siguiente:

$$Share_Occupation_{i,s,o,t} = \beta_0 + \beta_1 \times IA_Adoption_{i,s,t} + \beta_2 \times GDPCap_{i,t} + \beta_3 \times Educ_Rate_{i,t} + \beta_4 \times Unemp_Rate_{i,t} + \sum_{o \neq oc2} \gamma_o [Occupation_o \times IA_Adoption_{i,s,t}] + \sum_s \delta_s [Sector_s] + \mu_i + \lambda_t + \varepsilon_{i,s,o,t}$$

Donde:

- i = país
- o = ocupación (clasificación ISCO-08; el grupo OC2 se toma como categoría base, por eso el sumatorio excluye $o=OC2$)
- t = año
- μ_i = efectos fijos de país
- λ_t = efectos fijos de tiempo
- $\varepsilon_{i,s,t}$ = término de error idiosincrático

Este modelo incluye la interacción entre la adopción de IA y los grupos ocupacionales definidos según ISCO-08, usando como categoría base OC2 (Profesionales científicos e intelectuales). El coeficiente β_1 mide el efecto promedio estimado de la adopción de IA sobre la participación del empleo del grupo base (OC2), mientras que los coeficientes γ_o capturan los efectos diferenciales estimados para cada grupo ocupacional respecto al grupo base. Además, se introducen variables dummy sectoriales (δ_s) para controlar diferencias estructurales constantes entre sectores económicos.

La variable `IA_Adoption`, al estar agregada por sector-país-año, es idéntica para todas las ocupaciones dentro de un mismo sector-país-año. Por lo tanto, el modelo estima cómo la distribución ocupacional del empleo varía entre sectores y países según su grado de penetración sectorial de IA, controlando por efectos fijos nacionales y temporales.

Para corregir posibles problemas de heterocedasticidad y correlación de los errores dentro de cada sector-país-año, se estiman errores estándar robustos agrupados a este nivel de clúster.

3.3. Comentario metodológico final

El efecto total de la adopción de IA en cada sector u ocupación se obtiene sumando el coeficiente estimado para la variable `IA_Adoption` (que representa la categoría base) y el coeficiente correspondiente a la interacción específica de cada sector u ocupación. A partir de esta combinación lineal se calculan también los errores estándar y los p-valores, permitiendo así evaluar estadísticamente la significancia del efecto diferencial de la IA sobre el empleo relativo en cada sector económico.

En el modelo sectorial y ocupacional, la variable principal de estudio está agregada por sector-país-año, y país-año para las variables de control, por tanto, los resultados obtenidos deben interpretarse con cautela, como asociaciones estadísticas a nivel agregado, y no como efectos causales individuales o directos.

La adopción sectorial de IA se mide a partir de muestras transversales independientes en cada año, lo que permite una interpretación válida sobre cómo varía la participación relativa del empleo según la intensidad sectorial promedio de adopción de IA, pero no proporciona evidencia causal estricta. Esta metodología garantiza un análisis robusto y representativo dentro de las limitaciones impuestas por los datos disponibles y el diseño transversal anual de la encuesta europea sobre TIC.

Si bien la metodología de panel aplicada es robusta para capturar efectos fijos no observados y heterogeneidad persistente entre grupos, cabe mencionar la posibilidad de que exista endogeneidad derivada de la causalidad inversa o la omisión de variables relevantes. Aunque en este trabajo no ha sido posible utilizar variables instrumentales o métodos experimentales debido a restricciones en los datos disponibles y en el alcance del proyecto, futuras investigaciones podrían abordar esta cuestión empleando instrumentos tales como retrasos en la adopción tecnológica, shocks regulatorios específicos sobre inteligencia artificial o eventos históricos que afecten de manera exógena la introducción de IA en ciertos sectores. Reconocer explícitamente esta limitación metodológica permite interpretar prudentemente nuestros resultados y abre la puerta a futuras líneas de investigación.

4. ANÁLISIS DESCRIPTIVO DE LA ADOPCIÓN DE IA Y EL EMPLEO

Antes de proceder al análisis econométrico, se realiza un análisis descriptivo de las principales variables utilizadas en los modelos sectorial y ocupacional. Como se menciona en el apartado anterior, la adopción de IA por sector se mide a partir de muestras transversales independientes para países europeos.

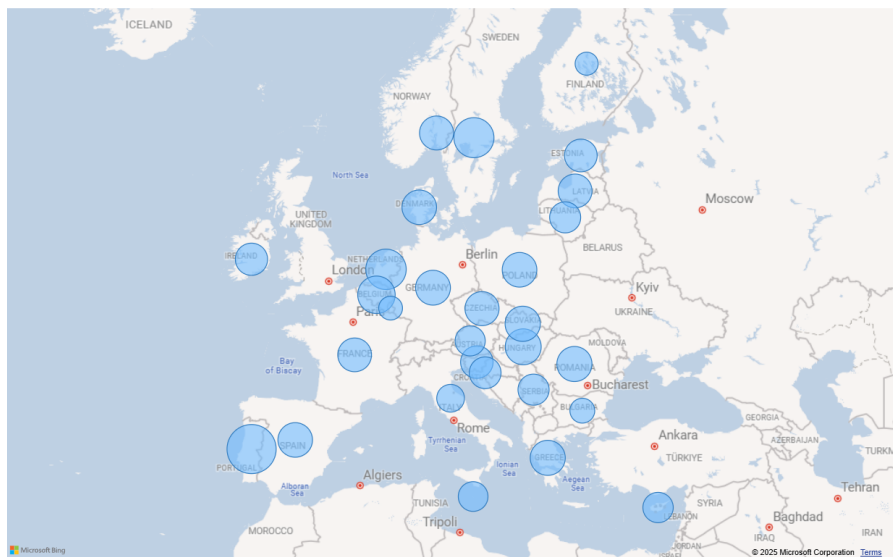


Figura 1. Distribución de las observaciones de IA_Adooption por país en Europa (2023-2024)
Fuente: Elaboración propia a partir de datos de Eurostat (Digital Economy and Society dataset, 2023-2024).

La Figura 1 muestra la distribución de las observaciones de adopción de IA para los 29 países europeos en el periodo 2023-2024, indicando una correcta homogeneidad de la distribución de los datos que observamos.

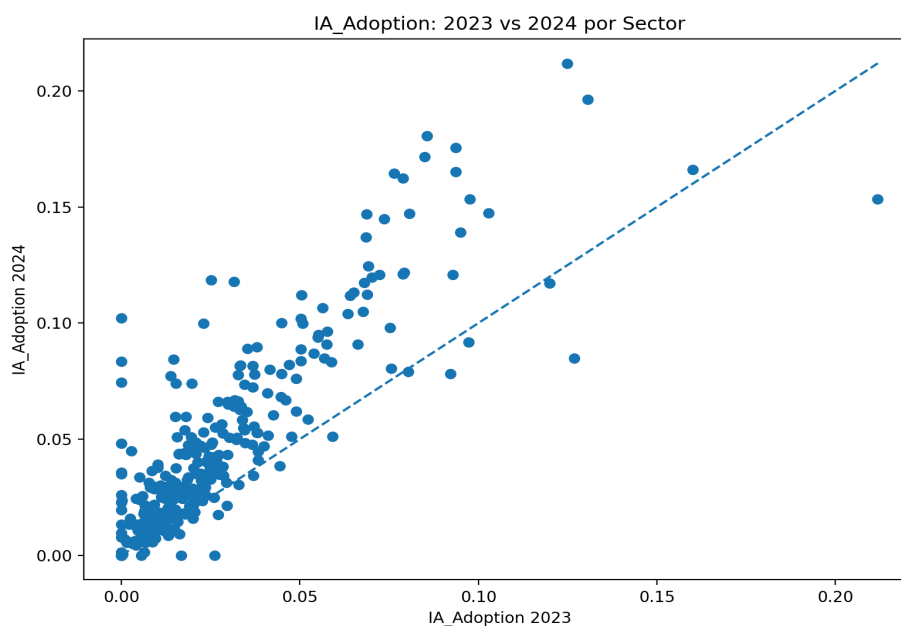


Figura 2. Comparación de la adopción de IA por sector: 2023 vs 2024. Fuente: Elaboración propia con datos de Eurostat (Digital Economy and Society dataset, 2023-2024).

En la Figura 2, se puede observar un notable crecimiento en el nivel de adopción de IA entre el periodo 2023 y 2024, con una distribución concentrada en valores inferiores a 5%, indicando un bajo nivel de implementación de IA en los sectores económicos en el periodo observado.




Figura 3 y 4. Número de observaciones de adopción de IA a nivel de empresa por sector (NACE). Número de observaciones de adopción de IA agregadas por sector (sector-país-año, NACE). Fuente: Elaboración propia con datos de Eurostat (Digital Economy and Society dataset, 2023-2024).

En la Figura 3 se identifica una distribución de las observaciones concentrada en el sector de la Industria manufacturera (sección C de la NACE) con más de 2500 observaciones del nivel de adopción de IA en las empresas. La Figura 4 muestra las observaciones una vez se agregan por sectores, obteniendo una distribución más homogénea para cada sector, con 40-60 observaciones para cada sector.

Tabla 1. Estadísticos descriptivos del panel sectorial utilizado en el modelo (2023-2024)

Var. Sector	Media	Desv. Est.	Mínimo	Máximo
IA_Adoption	0,0381	0,0378	0,0000	0,2500
Share Sector	0,0569	0,0494	0,0012	0,2528
GDP Cap	33140,59	20743,58	8520,00	101450,00
Educ_Rate	0,3991	0,0849	0,2288	0,5811
Unemp_Rate	0,0579	0,0221	0,0260	0,1220
RTI	-0,4221	0,2179	-0,9000	0,4203
NRA	0,2242	0,1412	0,0000	0,5900
NRI	0,1973	0,0776	0,0100	0,3417
RC	0,1939	0,0557	0,0500	0,3956
RM	0,0952	0,0879	0,0000	0,5200
NRM	0,2877	0,1611	0,0200	0,8400
Mean_RTI	-0,4492	0,2122	-0,8911	0,4289

Fuente: elaboración propia a partir de Eurostat (Digital Economy and Society dataset y EU-LFS, 2023-2024)

La Tabla 1 recoge los estadísticos descriptivos de las variables clave del modelo a nivel sectorial: el grado de adopción de IA por parte de las empresas (IA_Adoption), la participación relativa del empleo sectorial (Share_Sector), el PIB per cápita real (GDP Cap), el nivel educativo terciario (Educ_Rate), la tasa de desempleo (Unemp_Rate), el índice de intensidad rutinaria sin pesos (RTI) y el índice de intensidad rutinaria con pesos (Mean_RTI). Además, se desagrega el índice de intensidad por sub-tareas (sin pesos) para

cada sector: tareas cognitivas rutinarias (RC), tareas manuales rutinarios (RM), tareas analíticas no rutinarias (NRA), tareas interactivas no rutinarias (NRI) y tareas manuales no rutinarias (NRM).




Figura 5 y 6. Distribución de IA_Adoption en el panel sectorial (2023-2024). Distribución de Share_Sector en el panel sectorial (2023-2024). Fuente: elaboración propia a partir de Eurostat (Digital Economy and Society dataset y EU-LFS).

Se representan las variables principales de estudio a nivel sectorial por medio de histogramas de frecuencia. Se observa que la adopción de IA muestra valores relativamente bajos en promedio entre los sectores económicos con una media cercana al 4%, concentrados en valores próximos a cero y algunos valores máximos del 25%, lo que indica que sólo una pequeña fracción de sectores alcanza niveles elevados de adopción y un nivel de penetración moderado.

La participación relativa del empleo sectorial presenta una media cercana al 6%, oscilando entre valores mínimos de 0.1% y máximos del 25%, con una distribución más dispersa, lo que refleja la heterogeneidad en la distribución del empleo relativo entre sectores, sin que predomine un único patrón, aunque sí se observa mayor frecuencia en valores bajos.

Las variables de control (PIB per cápita, nivel educativo y tasa de desempleo) presentan una variabilidad significativa, acorde a las diferencias estructurales entre países y sectores en Europa.

El índice de intensidad rutinaria sin pesos y el índice de intensidad rutinaria con pesos muestran ser muy próximos, y con una media negativa cercana al -45%, lo que sugiere que, en promedio, los sectores son poco intensivos en tareas rutinarias, con valores que oscilan entre los mínimos del -89% (muy poco intensivos en tareas rutinarias) y máximos del 43% (intensivos en tareas rutinarias). Al analizar por sub-tareas se identifica, en promedio, una distribución uniforme de los valores para las tareas dentro de NRA, NRI, RC y NRM, con una media cercana al 20%, mientras que tareas dentro de RM, se observa un índice de intensidad promedio cercano al 10%. No se observa ningún resultado máximo o mínimo alarmante para las subcategorías de tareas.

Tabla 2. Estadísticos descriptivos del panel ocupacional utilizado en el modelo (2023-2024)

Var. Occupation	Media	Desv. Est.	Mínimo	Máximo
IA_Adoption	0,0381	0,0378	0,0000	0,2500
Share_Occupation	0,1000	0,1577	0,0000	1,0000
GDP_Cap	33140,59	20729,08	8520,00	101450,00
Educ_Rate	0,3991	0,0848	0,2288	0,5811
Unemp_Rate	0,0579	0,0221	0,0260	0,1220
Share Sector	0,0569	0,0494	0,0012	0,2528

Fuente: elaboración propia a partir de Eurostat (Digital Economy and Society dataset y EU-LFS, 2023-2024)

Seguidamente se presenta la tabla 2, que recoge los estadísticos descriptivos de las variables clave del modelo a nivel ocupacional: el grado de adopción de IA por parte de las empresas (IA_Adoption), la participación relativa del empleo sectorial (Share_Sector), el PIB per cápita real (GDP_Cap), el nivel educativo terciario (Educ_Rate), la tasa de desempleo (Unemp_Rate) y la participación relativa del empleo ocupacional (Share_Occupation).




Figura 7 y 8. Distribución de IA_Adoption en el panel ocupacional (2023-2024). Distribución de Share_Occupation en el panel ocupacional (2023-2024). Fuente: elaboración propia a partir de Eurostat (Digital Economy and Society dataset y EU-LFS).

De la misma manera que el modelo sectorial, se representan las variables principales de estudio a nivel ocupacional por medio de histogramas de frecuencia. Se comprueba que la distribución de la adopción de IA es la misma que para el sectorial, concentrado en valores bajos, lo que confirma la limitada penetración de la IA en el tejido empresarial europeo en el periodo analizado.

La participación relativa del empleo ocupacional muestra una media algo superior a la sectorial, con una media próxima al 10%, aunque con una desviación estándar notablemente mayor y valores máximos iguales al 100%. El histograma muestra una fuerte concentración en valores próximos a cero, con una disminución progresiva en frecuencias a medida que aumenta el peso relativo de ciertas ocupaciones, reflejando la existencia de grupos ocupacionales que representan una pequeña proporción del empleo, frente a otros mucho más relevantes.

En ambos paneles, no se detectan valores extremos anómalos que justifiquen la exclusión de variables, si bien la marcada asimetría en la adopción de IA será relevante a la hora de interpretar los efectos marginales en los modelos econométricos.

5. RESULTADOS ECONOMETRICOS

A continuación, se sintetizan los principales hallazgos de los modelos econométricos, donde la Tabla 3 corresponde al modelo sectorial⁵ (clasificación NACE Rev. 2), y la Tabla 4 al modelo ocupacional⁶ (clasificación ISCO-08). Cada tabla incluye los coeficientes estimados, errores estándar, número de observaciones y R^2 de las estimaciones de interés de estudio, mediante MCO.

5.1. Resultados sectoriales

TABLA 3

EFECTOS DE LA ADOPCIÓN DE IA SOBRE LA ESTRUCTURA SECTORIAL DEL EMPLEO			
DATOS DE PANEL CON EFECTOS FIJOS, 2023-2024			
IA_Adoption	0.2576***	(0.0775)	p=0.0009
IA x NACE_C	-0.7550*	(0.4196)	p=0.0725
IA x NACE_D	-0.2682***	(0.0768)	p=0.0005
IA x NACE_E	-0.2484***	(0.0886)	p=0.0052
IA x NACE_F	-0.6467**	(0.2517)	p=0.0104
IA x NACE_G	-0.7006***	(0.2422)	p=0.0040
IA x NACE_H	-0.5521***	(0.1515)	p=0.0003
IA x NACE_I	-0.0900	(0.1518)	p=0.5535
IA x NACE_J	-0.1601**	(0.0658)	p=0.0153
IA x NACE_L	-0.1149*	(0.0697)	p=0.0996
IA x NACE_N	-0.0687	(0.0769)	p=0.3721
IA x NACE_S	-0.1862**	(0.0746)	p=0.0128
R2 (Within)			0.8412
Nº Obs			644

Nota: Errores estándar entre paréntesis. (***) 1%, (**) 5%, (*) 10%. Errores robustos clusterizados.

Variables de Control: GDPCap, Educ_Rate, Unemp_Rate

Efectos incluidos: Entidad, Tiempo


La Tabla 3 revela que la adopción de IA está estadísticamente asociada de forma significativa con variaciones en la estructura sectorial del empleo, donde el nivel de intensidad difiere según el sector económico observado. En conjunto, las variables explicativas del modelo

⁵ Tabla A1 (Anexo). Resultados completos del modelo sectorial: coeficientes, errores estándar robustos y estadísticos de ajuste (Eurostat, 2023-2024)

⁶ Tabla A2 (Anexo). Resultados completos del modelo ocupacional: coeficientes, errores estándar robustos y estadísticos de ajuste (Eurostat, 2023-2024)

logran explicar un 84.12% de la variabilidad en la participación del empleo sectorial, que se interpreta como un elevado poder explicativo. Los coeficientes de interacción permiten identificar cómo difiere el impacto de la IA en cada sector económico en relación con el sector base (actividades profesionales, científicas y técnicas).

La variable regresora *IA_Adoption* hace referencia al sector económico de actividades profesionales, científicas y técnicas (correspondiente a la sección M de la NACE Rev. 2) establecida como categoría base, con un coeficiente estimado que indica una asociación positiva para el sector de servicios profesionales. Su interpretación nos dice que, por cada aumento de un punto porcentual (0.01 en términos proporcionales) en el nivel agregado de adopción de IA, el empleo relativo del sector de servicios profesionales se asocia, en promedio, con un incremento de 0.2576 puntos porcentuales, manteniendo constantes los demás factores. Este efecto es significativo con un intervalo de confianza del 99%, por lo que es muy poco probable estadísticamente que sea producto del azar.



Nota: Efectos totales calculados como suma del coeficiente “*IA_Adoption*” y las interacciones con cada sector a partir del modelo de panel con efectos fijos por sector-país y tiempo. Barras verticales muestran intervalos de confianza al 95%. Fuente: elaboración propia a partir de estimaciones de PanelOLS con datos de Eurostat (*Digital Economy and Society dataset* y *EU-LFS*).

La Figura 9 muestra los efectos totales de la adopción de IA en cada sector económico⁷, calculados como la suma del efecto base y el diferencial sectorial, permitiendo una interpretación directa de los impactos en cada sector. Se observa una asociación heterogénea que vincula la IA con incrementos en la participación del empleo de ciertos sectores, y efectos disruptivos de desplazamiento sectorial en otros.

⁷ Tabla A8 (Anexo). Efectos totales de la adopción de IA sobre la participación del empleo por sector NACE (panel 2023-2024)

Se destacan con un efecto positivo y significativo el sector de actividades relacionadas con la información y comunicaciones (sección J de la NACE Rev. 2), el sector de actividades inmobiliarias (sección L de la NACE Rev. 2), el sector relacionado con actividades administrativas y de servicios auxiliares (sección N de la NACE Rev. 2) y las actividades catalogadas dentro de otros servicios (sección S de la NACE Rev. 2).

En el sector de la información y comunicación (TIC) y las actividades agrupadas en otros servicios, el efecto es moderado y significativo donde, en términos de efectos estimados, se observa que, por cada aumento de un punto porcentual en el nivel de adopción de IA, el empleo relativo se asocia con un incremento de, en promedio, 0.0975 y 0.0713 puntos porcentuales respectivamente, manteniendo los demás factores constantes. Estos resultados reflejan un efecto positivo, pero estadísticamente inferior frente al sector profesional según la comparación de coeficientes representadas en la Tabla 1.

En el sector inmobiliario y el sector de actividades administrativas, el efecto es fuerte y significativo, donde, en términos estimados, el empleo relativo se asocia con un incremento de 0.1427 y 0.1889 puntos porcentuales respectivamente en estos sectores por cada aumento de un punto porcentual en el nivel de adopción de IA, manteniendo los demás factores constantes. Para mayor énfasis, no se logra observar un efecto estadísticamente diferente (con un intervalo de confianza del 95%) al sector de servicios profesionales según la comparación de coeficientes en los datos observados, por tanto, no podemos concluir un efecto diferente en estos sectores.

Por otro lado, se destacan con un efecto negativo y significativo el sector de actividades relacionadas con el comercio al por mayor y al por menor, reparación de vehículos de motor y motocicletas (sección G de la NACE Rev. 2) y el sector del transporte y almacenamiento (sección H de la NACE Rev. 2). Ambos sectores presentan una asociación negativa fuerte y significativa que, en términos estimados, la participación relativa disminuye en 0.4431 y 0.2945 puntos porcentuales respectivamente por cada aumento de un punto porcentual en el nivel de adopción de IA, manteniendo los demás factores constantes.

El resto de los sectores —correspondientes a las secciones C (Industria manufacturera), D (Suministro de energía eléctrica, gas, vapor y aire acondicionado), E (Suministro de agua, actividades de saneamiento, gestión de residuos y descontaminación), F (Construcción) e I (Hostelería y servicios de comida), según la clasificación NACE Rev. 2—, no resultaron significativos (con un intervalo de confianza del 95%), por lo que no hay evidencia suficiente de que la adopción de IA tenga un efecto significativamente diferente de cero en la participación del empleo relativo en dichos sectores.

Los resultados a nivel sectorial apoyan la idea de que en sectores de alta cualificación que requieren capacidades cognitivas avanzadas como el sector de servicios profesionales, la IA sigue un patrón complementario, asociado a un incremento en la participación del empleo en el sector, mientras que en sectores de baja cualificación y que no requieren capacidades cognitivas avanzadas, como el sector del comercio, la IA sigue un patrón sustitutivo, asociado a una disminución en la participación del empleo en el sector.

5.2. Resultados ocupacionales

TABLA 4

EFECTOS DE LA ADOPCIÓN DE IA SOBRE LA ESTRUCTURA OCUPACIONAL DEL EMPLEO			
DATOS DE PANEL CON EFECTOS FIJOS, 2023-2024			
IA_Adoption	3.7070***	(0.3058)	p=0.0000
OC1 × IA_Adoption	-3.6667***	(0.2931)	p=0.0000
OC3 × IA_Adoption	-3.2168***	(0.3464)	p=0.0000
OC4 × IA_Adoption	-3.8067***	(0.3552)	p=0.0000
OC5 × IA_Adoption	-5.0329***	(0.4149)	p=0.0000
OC6 × IA_Adoption	-3.7063***	(0.3064)	p=0.0000
OC7 × IA_Adoption	-4.7219***	(0.4540)	p=0.0000
OC8 × IA_Adoption	-4.6392***	(0.3546)	p=0.0000
OC9 × IA_Adoption	-4.5724***	(0.3500)	p=0.0000
OC0 × IA_Adoption	-3.7071***	(0.3058)	p=0.0000
R2 (Within)			0.2661
Nº Obs			6440


Nota: Errores estándar entre paréntesis. (***) 1%, (**) 5%, (*) 10%. Errores robustos clusterizados.

Variables de Control: GDPCap, Educ_Rate, Unemp_Rate

Efectos incluidos: Entidad, Tiempo

La tabla 4, muestra que la adopción de IA está asociada de forma significativa con variaciones en la estructura ocupacional del empleo y difiere según el grupo jerárquico observado. En conjunto, el modelo logra explicar un 26.61% de la variabilidad de la participación del empleo ocupacional en cada sector, lo que indica que existen otras fuentes de variación no capturadas por los controles del modelo. Los coeficientes de interacción permiten contrastar el efecto de la IA en cada grupo ocupacional a diferencia del grupo base (profesionales, científicos e intelectuales).

El coeficiente de la variable regresora *IA_Adoption* muestra una asociación positiva fuerte de la adopción de IA en el empleo relativo del grupo jerárquico que incluye a profesionales, científicos e intelectuales (correspondiente al grupo jerárquico OC2 de la ISCO-08), establecida como categoría base. En términos numéricos, por cada aumento de un punto porcentual en el nivel de adopción de IA, el empleo relativo de los profesionales aumenta, en promedio, 3.7070 puntos porcentuales, si se mantienen todos los demás factores constantes. Con un p-valor < 0.01, se confirma que la varianza del empleo relativo para los profesionales se relaciona con un incremento en la adopción de IA, con un intervalo de confianza del 99%, por tanto, es poco probable estadísticamente que sea producto del azar.



Nota: Efectos totales calculados como suma del coeficiente “IA_Adoption” y las interacciones con cada grupo ocupacional a partir del modelo de panel con efectos fijos por sector-país y tiempo. Barras verticales muestran intervalos de confianza al 95%. Fuente: elaboración propia a partir de estimaciones de PanelOLS con datos de Eurostat (Digital Economy and Society dataset y EU-LFS).

La figura 10 adopta la misma metodología que el anterior, donde se muestran los efectos totales de la adopción de IA para cada grupo jerárquico⁸, calculados como la suma del efecto base y el diferencial ocupacional. Igual que en el análisis sectorial, se observa un efecto heterogéneo, que asocia a la IA con incrementos en la participación del empleo de ciertos grupos de ocupaciones y efectos disruptivos de desplazamiento ocupacional en otros.

Con un efecto positivo y significativo destacan las ocupaciones de técnicos y profesionales de nivel medio (grupo OC3 de la ISCO-08). En términos de efecto estimado se observa que, por cada aumento de un punto porcentual en el nivel de adopción de IA, el empleo relativo se asocia con un incremento de, en promedio, 0.4902 puntos porcentuales, manteniendo los demás factores constantes. Por tanto, es un efecto considerable pero estadísticamente inferior y solapado por el sector profesional, observado en la comparación de coeficientes de la Tabla 2.

En cambio, en las ocupaciones de servicios y ventas (grupo OC5 de la ISCO-08), operarios cualificados (grupo OC7 de la ISCO-08), operadores de maquinaria (grupo OC8 de la ISCO-08) y ocupaciones elementales (grupo OC9 de la ISCO-08) se manifiesta un efecto negativo y muy significativo, que, en términos de efectos estimados, por cada aumento de un punto porcentual en el nivel de adopción de IA, el empleo relativo se asocia con una disminución de, en promedio, 1.3259, 1.0149, 0.9322 y 0.8654 puntos porcentuales para cada sector respectivamente, manteniendo los demás factores constantes.

⁸ Tabla A9 (Anexo). Efectos totales de la adopción de IA sobre la participación del empleo por ocupación ISCO-08 (panel 2023-2024)

Para el resto de las ocupaciones —correspondientes a los grupos OC1 (Directores y gerentes), OC4 (Personal de apoyo administrativo), OC6 (Agricultores y trabajadores calificados agropecuarios, forestales y pesqueros) y OC0 (Ocupaciones militares) según la clasificación ISCO-08—, los coeficientes resultaron no significativos, por lo que no hay evidencia suficiente de que la adopción de IA tenga un efecto diferente de cero en la participación del empleo relativo de dichos grupos ocupacionales.

Los resultados a nivel ocupacional apoyan la idea de un efecto heterogéneo que difiere según el tipo de tareas de cada grupo jerárquico. Las observaciones muestran un efecto complementario en las ocupaciones de los profesionales y técnicos, caracterizados por su alto nivel de cualificados e intensivo en tareas cognitivas avanzadas, creativas y poco rutinarias. Al contrario, se observa un efecto sustitutivo en ocupaciones no rutinarias caracterizadas por su bajo nivel de cualificados y capacidades cognitivas.

5.3. Conclusiones de los resultados econométricos

Los resultados econométricos obtenidos revelan asociaciones estadísticamente significativas entre la adopción agregada de inteligencia artificial y cambios en la estructura sectorial y ocupacional del empleo en Europa durante el período 2023-2024.

A nivel sectorial, se observa un patrón claro de heterogeneidad, donde sectores altamente intensivos en capital humano y tareas cognitivas avanzadas, como las actividades profesionales, científicas y técnicas (sección M de la NACE), la información y comunicación (sección J de la NACE), actividades inmobiliarias (sección L de la NACE), y actividades administrativas y servicios auxiliares (sección N de la NACE), un mayor nivel de adopción de IA se relaciona positivamente con una mayor participación relativa del empleo. Este resultado se alinea con la literatura que señalan un efecto de complementariedad entre IA y tareas cognitivas no rutinarias. Por el contrario, sectores como el comercio (sección G de la NACE) y el transporte y almacenamiento (sección H de la NACE), que presentan un perfil de tareas menos intensivas en capital humano y más susceptible a la automatización rutinaria o semi-rutinaria, muestran asociaciones negativas fuertes y significativas con la adopción de IA. Este hallazgo respalda parcialmente la hipótesis de desplazamiento sectorial del empleo hacia sectores más intensivos en habilidades cognitivas avanzadas.

En el modelo ocupacional, los resultados refuerzan la existencia de un patrón heterogéneo según la naturaleza de las tareas predominantes en cada grupo ocupacional. La adopción de IA está positivamente asociada con una mayor participación relativa del empleo en ocupaciones altamente cualificadas, como profesionales científicos e intelectuales (grupo OC2 de la ISCO-08), y técnicos y profesionales de nivel medio (grupo OC3 de la ISCO-08), quienes realizan tareas predominantemente cognitivas y analíticas no rutinarias. En cambio, ocupaciones de menor cualificación o aquellas intensivas en tareas manuales no rutinarias, como trabajadores de servicios y ventas (grupo OC5 de la ISCO-08), operarios cualificados (grupo OC7 de la ISCO-08), operadores de maquinaria (grupo OC8 de la ISCO-08) y ocupaciones elementales (grupo OC9 de la ISCO-08), presentan asociaciones negativas significativas con niveles más altos de penetración de IA.

Es importante enfatizar que estos resultados reflejan asociaciones estadísticas obtenidas con datos agregados sectoriales y ocupacionales, por tanto, no pueden atribuirse de manera concluyente efectos directos causales individuales a la adopción de IA.

En definitiva, estos resultados resaltan patrones diferenciados según el perfil de tareas del empleo sectorial y ocupacional, y aportan evidencia empírica consistente con teorías recientes sobre el impacto heterogéneo de las tecnologías avanzadas en el mercado laboral.

6. MODELOS MACROECONÓMICO

6.1. Modelo teórico de tareas no rutinarias vs rutinarias

Para entender los posibles efectos asociados a la adopción de inteligencia artificial en la estructura del empleo sectorial y ocupacional, planteamos un modelo macroeconómico sencillo basado en la teoría de las tareas rutinarias y no rutinarias. Este modelo considera que la producción en un sector puede descomponerse según la intensidad relativa de dos tipos de tareas: aquellas susceptibles de ser automatizadas (tareas rutinarias) y aquellas más difíciles de sustituir (tareas no rutinarias), típicamente asociadas a habilidades cognitivas avanzadas o creativas.

Definimos:

- l_N : proporción del empleo con alta intensidad en tareas no rutinarias (cognitivas, creativas).
- l_R : proporción del empleo con alta intensidad en tareas rutinarias (mecánicas, repetitivas).

Asumimos que la producción sectorial Y_{it} , en un país i y año t , depende del capital K_{it} , del trabajo en tareas no rutinarias l_N , y del trabajo en tareas rutinarias l_R . Introducimos la adopción de IA ($IA_Adoption$) como un factor que potencialmente complementa las tareas no rutinarias y sustituye las tareas rutinarias, reflejada en la siguiente función de producción Cobb-Douglas:

$$Y_{i,t} = AK^\alpha L^{(1-\alpha)}$$

Donde:

$$L = [\beta \times (IA_Adoption \times l_N)^\rho + (1 - \beta) \times (\frac{l_R}{IA_Adoption})^\rho]^{(1/\rho)}$$

$$L = l_N + l_R$$

Resultando:


$$Y_{i,t} = AK^\alpha [\beta \times (IA_Adoption \times l_N)^\rho + (1 - \beta) \times (\frac{l_R}{IA_Adoption})^\rho]^{(1-\alpha)/\rho}$$

- $\alpha \in (0,1)$: Elasticidad del output respecto al capital.
- $\rho \in (0,1)$: Parámetro de sustitución CES entre los dos agregados de trabajo.
- $\beta \in (0,1)$: Peso relativo de las tareas no rutinarias dentro del trabajo total.

Por tanto, el modelo sugiere que la asociación entre la adopción de IA y el empleo dependerá de la composición del trabajo en cada sector, así como de la elasticidad capital-trabajo y del grado de sustitución entre tareas rutinarias y no rutinarias. En sectores con predominancia de tareas rutinarias, un aumento en la adopción de IA tendería a asociarse con una reducción del empleo relativo, dado que la productividad incrementada podría sustituir trabajadores.

Por el contrario, en sectores con una mayor proporción de tareas no rutinarias, la IA podría complementar al trabajo humano, elevando la productividad sin desplazar necesariamente empleo.

Para analizar cómo la adopción de IA se relaciona con el empleo en diferentes sectores económicos, consideramos el tipo de tareas predominantes en cada ocupación. La literatura económica ha demostrado que el cambio tecnológico tiende a automatizar tareas rutinarias repetitivas, mientras que complementa tareas no rutinarias que requieren razonamiento analítico, creatividad o interacción interpersonal (Autor, Levy y Murnane, 2003).



Nota: Distribución del RTI agregado a nivel de una cifra (ISCO-08) usando ponderaciones de empleo por ocupación de cuatro dígitos en los Países Bajos en 2017 (CBS StatLine). Fuente: elaboración propia a partir de Mihaylov y Tijdens (2019).

Para categorizar cada grupo ocupacional (según ISCO-08), utilizamos el índice de intensidad rutinaria (RTI) desarrollado por Mihaylov y Tijdens (2019). Este índice proporciona una medida continua que refleja el grado de rutina promedio en cada ocupación a nivel agregado europeo, considerando la proporción ponderada de diferentes tipos de tareas.

A partir de los valores RTI específicos de cada ocupación, se calculó una medida ponderada (según la proporción del empleo ocupacional, *Share_Occupation*) del RTI para cada combinación país-año-sector. Este índice ponderado (RTI promedio sectorial) permite evaluar empíricamente si la relación entre la adopción de IA y la estructura sectorial del empleo varía sistemáticamente con la intensidad de tareas rutinarias.

Para comprobar empíricamente esta hipótesis, se estimó un modelo de datos de panel con efectos fijos, con la siguiente especificación econométrica:

$$Share_Sector_{i,s,t} = \beta_0 + \beta_1 \times IA_Adoption_{i,s,t} + \beta_2 \times (IA_Adoption \times RTI)_{i,s,t} + \gamma_1 \times GDPCap_{i,t} + \gamma_2 \times Educ_Rate_{i,t} + \gamma_3 \times Unemp_Rate_{i,t} + \mu_i + \lambda_t + \varepsilon_{i,s,t}$$

Donde:

- μ_i : Son los efectos fijos entidad (sector-país).
- λ_t : Son los efectos fijos temporales (año).
- ε_{it} : Es el término de error.

En este marco, el coeficiente β_1 mide la asociación entre la adopción de IA y el empleo sectorial cuando RTI=0 (nivel promedio de intensidad rutinaria), mientras que β_2 captura cómo esta asociación cambia cuando aumenta o disminuye la intensidad relativa de tareas rutinarias. Se espera que sectores con un RTI más alto (más tareas rutinarias) muestren una asociación menos favorable con el empleo relativo al aumentar la adopción de IA, mientras que aquellos con un RTI más bajo (predominio de tareas no rutinarias) presenten una asociación más positiva o menos negativa.

6.2. Resultados del modelo teórico de tareas no rutinarias vs rutinarias

La Tabla 5 presenta los resultados econométricos del primer modelo teórico, que analiza si la intensidad de tareas rutinarias regula la asociación entre la adopción de IA y la participación sectorial del empleo⁹.

TABLA 5

EFECTO DE LA ADOPCIÓN DE IA SOBRE LA ESTRUCTURA SECTORIAL DEL EMPLEO POR EL ÍNDICE DE INTENSIDAD EN TAREAS RUTINARIAS (RTI)			
DATOS DE PANEL CON EFECTOS FIJOS, 2023-2024			
IA_Adoption	0.0971	(0.2785)	p=0.7276
IA_Adoption x Mean_RTI	0.1467	(0.3867)	p=0.7046
R2 (Within)			0.0239
Nº Obs			644

Nota: Errores estándar entre paréntesis. (***) 1%, (**) 5%, (*) 10%. Errores robustos clusterizados.

Variables de Control: GDPCap, Educ_Rate, Unemp_Rate

Efectos incluidos: Entidad, Tiempo

El coeficiente de la interacción $IA \times RTI$ muestra el efecto de la adopción de IA sobre el empleo relativo sectorial cuando la intensidad en tareas rutinarias varía, con un resultado positivo de 0.1467 puntos porcentuales, pero no es estadísticamente significativo. De igual modo, el coeficiente de la variable principal $IA_Adoption$ relata el efecto de un aumento en el nivel de adopción de IA cuando la intensidad en tareas rutinarias es igual a cero, con un resultado positivo de 0.0971 puntos porcentuales, pero una vez más, no significativo. Estos resultados indican que, con los datos disponibles para el periodo 2023-2024, no se puede concluir que la intensidad rutinaria del empleo explique la heterogeneidad observada previamente en los efectos de la adopción de IA sobre el empleo relativo sectorial. Además, la baja capacidad explicativa del modelo (R^2 within = 0.0239) sugiere que hay factores no

⁹ Tabla A3 (Anexo). Resultados completos del modelo con RTI: coeficientes, errores estándar robustos y estadísticos de ajuste (Eurostat, 2023-2024)

considerados en el modelo que podrían explicar la variabilidad de la estructura sectorial del empleo.

En conclusión, el primer modelo teórico no permite confirmar la hipótesis inicial según la cual la intensidad rutinaria del trabajo regula significativamente la relación entre la adopción de IA y la estructura sectorial del empleo. Por tanto, en el siguiente apartado se procederá a explorar si una descomposición más detallada en los subcomponentes específicos de tareas puede aportar evidencia adicional que clarifique los patrones observados.

6.3. Modelo teórico de sub-tareas

Para obtener el índice de intensidad rutinaria, Mihaylov y Tijdens (2019) plantean el siguiente modelo:

$$RTI_k = RC_k + RM_k - NRA_k - NRI_k - NRM_k$$

Donde RTI indica la intensidad en tareas rutinarias de la ocupación k, compuesta por cinco categorías de tareas: cognitivas rutinarias (RC), manuales rutinarios (RM), analíticas no rutinarias (NRA), interactivas no rutinarias (NRI) y manuales no rutinarias (NRM).




Figura 12. Índice de intensidad de sub-tareas por grupo ocupacional (Mihaylov & Tijdens, 2019) – cálculo no ponderado. Proporciones promedio de las cinco categorías de tareas (cognitivas rutinarias – RC, manuales rutinarias – RM, analíticas no rutinarias – NRA, interactivas no rutinarias – NRI, y manuales no rutinarias – NRM) para cada una de las nueve ocupaciones de un dígito de ISCO-08, calculadas como media aritmética simple de las 427 ocupaciones de cuatro dígitos (sin aplicar ponderaciones de empleo). Fuente: elaboración propia a partir de Mihaylov y Tijdens (2019).

Para explorar en detalle cómo cada categoría específica de tareas influye en la relación entre la adopción de IA y la estructura sectorial del empleo, se construyeron proporciones promedio ponderadas para cada una de estas cinco categorías (NRA, NRI, RC, RM, NRM) por sector-país-año. Debido a que Mihaylov y Tijdens (2019) no proporcionan directamente los valores de estas categorías a nivel de grupos ocupacionales a un dígito (OC1-OC9), calculamos estos promedios manualmente. Para ello, se emplean las tablas con las 427 ocupaciones

detalladas (cuatro dígitos) del estudio original y se realiza una media aritmética simple por cada categoría ocupacional agregada, sin ponderar por empleo, debido a que no disponíamos de los pesos específicos de empleo utilizados por los autores para el RTI. Dado que las proporciones suman aproximadamente 1, existe una fuerte multicolinealidad, por ello se omite y establece como categoría base las tareas cognitivas rutinarias (RC), que representa el patrón tradicional de tareas más susceptible a la automatización clásica y sirve como punto de referencia.

Para contrastar empíricamente este modelo teórico, estimamos un modelo de datos de panel con efectos fijos por entidad (sector-país) y temporales (año), utilizando la siguiente especificación econométrica:

$$\begin{aligned} Share_Sector_{i,s,t} = & \beta_0 + \beta_1 \times IA_{i,s,t} + \beta_2 \times IA_{i,s,t} \times NRA_{i,s,t} + \beta_3 \times IA_{i,s,t} \times NRI_{i,s,t} + \\ & \beta_4 \times IA_{i,s,t} \times RM_{i,s,t} + \beta_5 \times IA_{i,s,t} \times NRM_{i,s,t} + \gamma_1 \times NRA_{i,s,t} + \gamma_2 \times NRI_{i,s,t} + \\ & \gamma_3 \times RM_{i,s,t} + \gamma_4 \times NRM_{i,s,t} + \delta_1 \times GDPCap_{i,t} + \delta_2 \times Educ_Rate_{i,t} + \delta_3 \times \\ & Unemp_Rate_{i,t} + \mu_i + \lambda_t + \varepsilon_{i,s,t} \end{aligned}$$

Donde:

- IA: IA_Adoption
- μ_i : Son los efectos fijos por entidad (sector-país).
- λ_t : Son los efectos fijos temporales (año).
- $\varepsilon_{i,t}$: Es el término de error.

En esta especificación, el coeficiente β_1 mide el efecto de la adopción de IA sobre la participación del empleo sectorial cuando la proporción de tareas cognitivas rutinarias (RC) es igual a 1. Los coeficientes β_2 , β_3 , β_4 y β_5 capturan cómo varía dicho efecto cuando incrementa la proporción de tareas analíticas no rutinarias, interactivas no rutinarias, manuales rutinarias y manuales no rutinarias, respectivamente, siempre en comparación con las tareas cognitivas rutinarias omitidas como categoría base. Esta estrategia nos permite evaluar en detalle si la adopción de IA está asociada diferencialmente con la participación sectorial del empleo según el tipo específico de tareas predominantes en cada sector.

6.4. Resultados del modelo teórico de sub-tareas

La Tabla 6 muestra los resultados del modelo teórico que considera la descomposición detallada de tareas en cinco categorías específicas¹⁰ (analíticas no rutinarias, interactivas no rutinarias, cognitivas rutinarias, manuales rutinarias y manuales no rutinarias).

¹⁰ Tabla A4 (Anexo). Resultados completos del modelo por sub- tareas: coeficientes, errores estándar robustos y estadísticos de ajuste (Eurostat, 2023-2024)

TABLA 6


EFECTO DE LA ADOPCIÓN DE IA SOBRE LA ESTRUCTURA SECTORIAL DEL EMPLEO POR SUB-TAREAS			
DATOS DE PANEL CON EFECTOS FIJOS, 2023-2024			
IA_Adoption	-0.5088	(0.9563)	p=0.1152
IA x NRA	-1.2431	(1.4655)	p=0.3966
IA x NRI	6.3001	(4.4038)	p=0.1531
IA x RM	7.6221**	(3.7066)	p=0.0402
IA x NRM	0.2166	(0.6198)	p=0.7269
R2 (Within)			0.2008
Nº Obs			644

Nota: Errores estándar entre paréntesis. (***) 1%, (**) 5%, (*) 10%. Errores robustos clusterizados.

Variables de Control: GDPCap, Educ_Rate, Unemp_Rate

Efectos incluidos: Entidad, Tiempo

La categoría base elegida para este modelo es la de tareas cognitivas rutinarias (RC), que representa el patrón clásico susceptible a la automatización. En contraste, el modelo explica un 20.08% de la variabilidad de la participación sectorial del empleo, lo que señala que existen variables explicativas no incluidas en el modelo.



Nota: Efectos totales calculados como suma del coeficiente "IA_Adoption" y las interacciones con cada sub-tarea (RC, NRA, NRI, RM, NRM) a partir del modelo de panel con efectos fijos por sector-país y tiempo. Barras verticales muestran intervalos de confianza al 95%. Fuente: elaboración propia a partir de resultados de regresión.

El efecto total de la adopción de IA sobre la participación sectorial del empleo por sub-tareas¹¹ es estadísticamente significativo únicamente en sectores dominados por tareas manuales rutinarias (RM), con un coeficiente positivo de 6.1133 puntos porcentuales. Esto implica que, en sectores con predominancia de actividades manuales repetitivas, la adopción de IA se asocia a una mayor participación relativa del empleo.

Para el resto de sub-tareas, los efectos totales no resultaron estadísticamente significativos, por tanto, estos resultados indican una evidencia limitada sobre la capacidad explicativa de las sub-tareas individuales en la heterogeneidad sectorial observada. Los efectos obtenidos deben interpretarse con precaución debido a la limitada extensión temporal de los datos disponibles y al uso de promedios simples no ponderados para los indicadores de tareas.

6.5. Conclusiones de los modelos teóricos (RTI y sub-tareas)

Los resultados obtenidos en ambos modelos teóricos planteados indican que, con los datos actualmente disponibles, la teoría basada en la intensidad rutinaria del trabajo no proporciona una explicación sólida y generalizada para la heterogeneidad observada en los efectos de la adopción de IA sobre el empleo sectorial.

En el primer modelo teórico, no encontramos evidencia estadística que indique que la intensidad rutinaria del empleo condicione significativamente la relación entre IA y empleo sectorial. Por otro lado, al realizar un análisis más detallado mediante la descomposición de tareas en subcategorías específicas, la única asociación clara y estadísticamente significativa fue la de tareas manuales rutinarias, mostrando una relación positiva con la participación relativa del empleo sectorial. Este resultado podría sugerir que ciertos sectores con predominancia en tareas repetitivas manuales podrían beneficiarse relativamente más de la adopción de IA, aunque este hallazgo debe interpretarse con cautela. La falta generalizada de significancia en las otras sub-tareas sugiere que la adopción de IA podría estar generando patrones de transformación en la estructura del empleo que no se capturan plenamente con los marcos analíticos clásicos de tareas rutinarias y no rutinarias.

Estos hallazgos resaltan la necesidad de investigaciones futuras con bases de datos más extensas en el tiempo y más detalladas a nivel microeconómico. Solo así será posible identificar claramente los mecanismos específicos a través de los cuales la inteligencia artificial impacta en la estructura sectorial y ocupacional del empleo.

¹¹ Tabla A10 (Anexo). Efectos totales: adopción de IA y participación del empleo sectorial por categoría de tarea (NRA, NRI, RC, NRM), 2023-2024

7. PRUEBAS DE ROBUSTEZ

Para asegurar la solidez de los resultados obtenidos en los modelos sectorial y ocupacional, se realizaron pruebas adicionales destinadas a evaluar dos supuestos fundamentales de las estimaciones econométricas: la ausencia de multicolinealidad severa y la homocedasticidad de los residuos.

En primer lugar, se calculó el Factor de Inflación de la Varianza (VIF) para detectar posibles problemas de multicolinealidad. Los resultados mostraron que, en el modelo sectorial¹², la mayoría de las variables presentaron VIF inferiores al umbral crítico de 10. Sin embargo, la variable `IA_Adoption` y su interacción con el sector de actividades relacionadas con la información y comunicaciones (sección J de la NACE) exhibieron valores ligeramente superiores de, 14.7 y 16.2, respectivamente. En el modelo ocupacional¹³, `IA_Adoption` presentó un VIF de 10.1, situándose en el límite recomendado, mientras que el resto de las variables e interacciones mostraron valores aceptables inferiores a 5. Estos valores más elevados se pueden explicar por la inclusión simultánea de múltiples interacciones con dummies sectoriales y ocupacionales, causando multicolinealidad entre las variables.

En segundo lugar, se aplicó la prueba de Breusch-Pagan¹⁴ para evaluar la presencia de heterocedasticidad, con las hipótesis siguientes:

- Hipótesis nula (H_0): los residuos son homocedásticos (varianza constante).
- Hipótesis alternativa (H_1): los residuos son heterocedásticos.

Los resultados revelaron claramente la presencia de heterocedasticidad en ambos modelos sectoriales y ocupacionales ($p < 0.001$), por tanto, para corregir este problema, se utilizaron errores estándar robustos clusterizados a nivel de entidad (sector-país) en todas las estimaciones. Esta corrección garantiza que las inferencias estadísticas sean válidas frente a la varianza no constante y las posibles correlaciones intra-grupo detectadas.

En resumen, las pruebas de robustez indican que, aunque existe cierta colinealidad moderada debido a la especificación de los modelos con múltiples interacciones, esta no es lo suficientemente severa para afectar sustancialmente los resultados, por tanto, no se omiten en los modelos ya que son relevantes para el estudio. Asimismo, los procedimientos adoptados para corregir la heterocedasticidad aseguran la robustez y consistencia de las conclusiones presentadas en esta tesis.

¹² Tabla A11 (Anexo). Factores de Inflación de la Varianza (VIF) del modelo sectorial, panel 2023-2024

¹³ Tabla A12 (Anexo). Factores de Inflación de la Varianza (VIF) del modelo ocupacional, panel 2023-2024

¹⁴ Tabla A13 (Anexo). Test de heterocedasticidad Breuch-Pagan por tipo de panel (sectorial y ocupacional)

8. DISCUSIÓN DE RESULTADOS E IMPLICACIONES

8.1. Contraste con la teoría

Los resultados obtenidos en esta investigación indican asociaciones heterogéneas entre la adopción de IA y la participación relativa del empleo sectorial y ocupacional en Europa durante el período 2023-2024. Estos hallazgos se contrastaron con el marco teórico clásico basado en la teoría de tareas rutinarias y no rutinarias, según la cual la automatización debería sustituir especialmente aquellas tareas rutinarias y complementar las no rutinarias.

Sin embargo, nuestros resultados no respaldaron completamente esta teoría. El modelo basado en el índice de intensidad rutinaria (RTI) agregados por sectores no mostró efectos significativos claros, indicando que la teoría clásica no logra explicar los patrones observados en las nuevas tecnologías de inteligencia artificial sobre la estructura sectorial del empleo. La desagregación en subcategorías específicas de tareas (sub-tareas) ofreció un único resultado significativo en las tareas manuales rutinarias (RM), sugiriendo que la IA podría complementar específicamente procesos manuales repetitivos. Este resultado desagregado por sub-tareas difiere de las teorías clásicas, y contradice la hipótesis de que la automatización sustituye aquellas tareas repetitivas, fácil de reemplazar por maquinaria o tecnologías avanzadas.

En definitiva, nuestros resultados sugieren que la reciente adopción de IA podría estar generando transformaciones en el mercado laboral europeo mediante mecanismos aún no plenamente explicados por las teorías existentes. No obstante, recalcamos las limitaciones del periodo y la ausencia de datos microeconómicos del empleo. Sin embargo, esto abre la puerta a futuras investigaciones centradas en identificar patrones que expliquen, empíricamente, cómo las nuevas tecnologías, especialmente la IA generativa, impactan de forma heterogénea sobre sectores y ocupaciones del marco laboral europeo.

8.2. Implicaciones sectoriales y de política

Aunque los resultados no permiten establecer relaciones causales definitivas, los patrones observados ofrecen implicaciones relevantes tanto para responsables de política pública como para empresas. En el plano sectorial, los sectores intensivos en capital humano (como los servicios profesionales y tecnológicos) muestran asociaciones positivas con la adopción de IA, lo que sugiere que estos sectores están mejor posicionados para beneficiarse de la automatización inteligente. Por el contrario, sectores de baja cualificación como el comercio o el transporte presentan correlaciones negativas, lo cual podría derivar en pérdidas relativas de empleo si no se implementan medidas de transición adecuadas.

A nivel ocupacional, se observa una tendencia hacia el desplazamiento del empleo hacia ocupaciones con alto contenido cognitivo (profesionales, técnicos), en detrimento de ocupaciones manuales o de servicios repetitivos. Esta dinámica puede agravar las desigualdades laborales si no se anticipa con políticas específicas.

En este contexto, resulta fundamental diseñar políticas activas de empleo centradas en:

- **Formación continua y recualificación**, con especial énfasis en habilidades digitales, análisis de datos y alfabetización en IA para trabajadores de sectores vulnerables.

- **Incentivos a la reconversión sectorial**, que apoyen la transición de pymes hacia modelos de negocio que integren tecnología sin destruir empleo.
- **Sistemas de protección y orientación laboral**, como subsidios temporales de transición o servicios públicos de orientación personalizados, especialmente en regiones más expuestas al cambio tecnológico.

Esta visión está alineada con los planteamientos de Acemoglu y Johnson (2023), quienes advierten que el desarrollo tecnológico no garantiza automáticamente mejoras en bienestar general. Según los autores, la dirección del cambio tecnológico puede ser sesgada hacia la automatización “excesiva” si no se orienta explícitamente a complementar y empoderar al trabajador. Por tanto, el papel del Estado no debe limitarse a amortiguar los efectos negativos del cambio tecnológico, sino también a modelar activamente los incentivos y el rumbo de la innovación, promoviendo aquellas aplicaciones de la IA que potencien las capacidades humanas y generen valor compartido.

La experiencia europea con la digitalización previa muestra que los efectos no son homogéneos ni inmediatos, por tanto, diseñar políticas proactivas y adaptadas a cada contexto productivo será clave para que la inteligencia artificial contribuya a un crecimiento inclusivo y sostenible.

9. CONCLUSIONES Y LIMITACIONES

9.1. Síntesis de hallazgos principales

Este trabajo investigó cómo la adopción de inteligencia artificial por parte de las empresas se relaciona con la estructura sectorial y ocupacional del empleo en Europa durante el período 2023-2024, utilizando datos agregados y modelos econométricos de panel. Los resultados obtenidos revelan asociaciones heterogéneas de la IA a lo largo de distintas ramas de actividad y categorías ocupacionales. En el plano sectorial, la adopción de IA se asoció con incrementos relativos de empleo en sectores intensivos en conocimiento (por ejemplo, servicios profesionales y tecnológicos) y, en contraste, con disminuciones en sectores tradicionalmente menos cualificados o de carácter más rutinario, como el comercio y el transporte. A nivel ocupacional, se observó también un desplazamiento en la composición del empleo, donde ocupaciones de alta cualificación, intensivas en tareas cognitivas avanzadas (tales como profesionales científico-intelectuales y técnicos), aumentaron su participación relativa, mientras que ocupaciones de menor cualificación (tales como trabajos de servicios y ventas) tendieron a reducir su peso relativo bajo mayores niveles de adopción de IA.

En relación con la hipótesis principal de que la adopción de IA afecta de forma heterogénea al empleo según la naturaleza de las tareas, la evidencia resultante es mixta. Al contrastar estos hallazgos con el marco teórico de tareas rutinarias vs. no rutinarias, se encontró evidencia mixta. Por un lado, los patrones agregados son consistentes con la idea de que la IA está beneficiando más a sectores y puestos de trabajo no rutinarios/cualificados, alineándose parcialmente con la hipótesis planteada. Sin embargo, las pruebas econométricas formales basadas en el índice global de intensidad rutinaria (RTI) no mostraron un efecto diferencial claro. El coeficiente de interacción entre IA y el nivel de intensidad rutinaria promedio de cada sector no resultó estadísticamente significativo. Esto indica que, considerando todos los sectores conjuntamente, el grado rutinario general de las tareas no explica significativamente la heterogeneidad observada. Ahora bien, al descomponer el análisis por subcategorías de tareas, emergió un resultado específico notable. En los sectores dominados por tareas manuales rutinarias, la adopción de IA se asoció con un aumento significativo de la participación del empleo. Dicho de otro modo, solo en esa categoría particular de tareas (manual-rutinarias) la IA mostró una relación positiva clara con el empleo, sugiriendo quizá un efecto de complementariedad inesperada (por ejemplo, la IA podría estar apoyando ciertas labores manuales repetitivas en lugar de sustituir completamente a los trabajadores). En las demás categorías de tareas analíticas o cognitivas, no se hallaron efectos estadísticamente significativos. En síntesis, la hipótesis se confirma parcialmente, donde la heterogeneidad sectorial y ocupacional es robusta, pero los índices RTI y la descomposición fina de tareas explican esa heterogeneidad sólo de forma limitada. Ello sugiere que otros factores (por ejemplo, la organización del trabajo o la estrategia tecnológica específica de cada empresa) también mediatizan el impacto de la IA, aspecto que futuras investigaciones deberán explorar con datos más desagregados y series temporales más largas.

En conjunto, estos hallazgos indican que la adopción reciente de IA en Europa no ha tenido un impacto uniforme. Se observaron ganadores y perdedores relativos, donde sectores intensivos en capital humano y ocupaciones de alta cualificación aparecen, en esta fase inicial, como los ganadores relativos, mientras que sectores de baja cualificación (y sus

correspondientes empleos rutinarios) han visto reducir su cuota de empleo. Al mismo tiempo, la clásica distinción entre tareas rutinarias y no rutinarias resultó ser demasiado agregada para explicar por completo las variaciones, con una sola subcategoría, tareas manuales rutinarias, resultando ser estadísticamente significativa. Estas conclusiones proporcionan evidencia empírica puntual sobre el mercado laboral europeo en 2023-2024, donde no se aprecia un efecto de destrucción masiva de empleo por la IA en términos netos, pero sí un reajuste estructural donde el empleo se está redistribuyendo hacia actividades y ocupaciones más orientadas a conocimientos avanzados, en detrimento de aquellas más rutinarias y de menor especialización.

9.2. Limitaciones del estudio

Las conclusiones de este estudio deben considerarse a la luz de varias limitaciones importantes, de carácter tanto metodológico como de datos:

En primer lugar, el horizonte temporal analizado es muy acotado. Al abarcar únicamente dos años (2023 y 2024), el estudio captura solo el impacto de corto plazo de la adopción de IA. Esto reduce la capacidad para identificar tendencias de largo plazo o efectos dinámicos. Un período tan breve también aumenta la sensibilidad de los resultados a eventos transitorios o coyunturales propios de esos años.

En segundo lugar, el análisis se basó en datos agregados por sector y ocupación, lo cual imposibilita establecer relaciones de causalidad directa a nivel microeconómico. Al trabajar con promedios sector-país, no podemos afirmar que la IA “cause” ciertos cambios en empleos individuales, pues podrían influir factores no observados correlacionados tanto con la adopción de IA como con el empleo (por ejemplo, cambios regulatorios o shocks de demanda en ciertos sectores). Si bien el uso de efectos fijos de país y año controla en parte algunas heterogeneidades, persiste el riesgo de sesgo por variables omitidas. En resumen, nuestros resultados muestran asociaciones significativas entre IA y empleo, pero no demuestran causalidad estricta.

En tercer lugar, existen limitaciones en los datos de adopción de IA utilizados. La principal fuente (encuesta TIC de Eurostat a empresas) ofrece un indicador amplio sobre uso de “alguna tecnología de IA”, pero no distingue entre tipos de IA (por ejemplo, IA generativa vs. otras aplicaciones) ni proporciona información detallada sobre la intensidad o calidad con que se usa la IA en los procesos productivos. Por tanto, la falta de un indicador específico de IA generativa es particularmente relevante, dado el énfasis de la discusión actual en ese tipo de tecnologías.

En cuarto lugar, las medidas empleadas para caracterizar el contenido de tareas en cada sector/ocupación conllevan simplificaciones. El índice agregado de intensidad rutinaria (RTI) asignado a cada sector proviene de promedios basados en datos previos (y en otro contexto, los Países Bajos, 2017), por lo que este índice puede no reflejar perfectamente las diferencias entre países ni captar matices intersectoriales. En la desagregación por sub-tareas, fue necesario suponer ponderaciones iguales, lo cual introduce un posible sesgo, ya que no todas las tareas tienen la misma relevancia cuantitativa en cada sector, y al no ponderar por empleo, la medida de sub-tareas podría sobre-representar o infra-representar ciertas actividades.

Finalmente, el tamaño muestral y la especificación podrían influir en la robustez de algunos resultados. Con solo 644 observaciones en el panel sectorial y múltiples variables de interacción, el poder estadístico es limitado para detectar efectos más sutiles. Algunos coeficientes estimados (especialmente en el modelo ocupacional) presentan significatividad marginal, por lo que habría que interpretarlos con prudencia. Si se dispusiera de más años o de datos a menor nivel de agregación del empleo, se podría ganar precisión en las estimaciones.

9.3. Agenda de investigación futura

Dadas las limitaciones y hallazgos de este estudio, se identifican varias líneas futuras de investigación que podrían ampliar y reforzar el conocimiento sobre IA y empleo:

- **Análisis con microdatos individuales y empresariales:** Incorporar datos a nivel de empresa o de trabajadores permitiría identificar con mayor claridad los mecanismos causales por los cuales la IA afecta al empleo (por ejemplo, saber si son ciertas tareas dentro de los puestos de trabajo las que se automatizan, o si la IA crea nuevos roles complementarios).
- **Extensión del horizonte temporal:** Es fundamental ampliar el período de estudio más allá de 2024. Un análisis que cubra la evolución en el mediano y largo plazo (por ejemplo, los próximos 5 a 10 años) capturaría efectos dinámicos de la adopción de IA, permitiendo observar si las tendencias de 2023-2024 se consolidan, se revierten o emergen nuevas dinámicas (como posibles recuperaciones del empleo tras ajustes iniciales).
- **Mejoras en la medición de tareas y tecnologías:** Desarrollar índices de tareas ajustados por peso de empleo a nivel nacional o sectorial podría proporcionar una representación más fiel de la estructura laboral real. Por ejemplo, si se logra ponderar las sub-tareas por la cantidad de trabajadores que las realizan efectivamente en cada sector, los análisis de rutina vs. no rutina serían más precisos.
- **Análisis con indicadores específicos de IA generativa:** futuras encuestas podrían separar la adopción de IA generativa de otras aplicaciones, lo cual permitiría investigar si ciertas clases de IA tienen efectos diferentes en el empleo.

En conclusión, ampliar la investigación en estas direcciones contribuirá a comprender mejor cómo la IA está moldeando el mercado laboral, ofreciendo bases más sólidas para formular políticas adecuadas. La rápida evolución de la IA hace imperativa la actualización continua del análisis con nuevos datos y métodos, de modo que académicos y responsables públicos puedan anticipar y gestionar sus impactos socioeconómicos de la manera más eficaz y equitativa posible.

REFERENCIAS

Acemoglu, D., & Johnson, S. (2023). *Power and progress : our thousand-year struggle over technology and prosperity / Daron Acemoglu and Simon Johnson*. Basic Books.

Acemoglu, D., & Restrepo, P. (2020). Robots and Jobs: Evidence from US Labor Markets. *Journal of Political Economy*, 128(6), 2188-2244. <https://doi.org/10.1086/705716>

Acemoglu, D., & Restrepo, P. (2022). Tasks, Automation, and the Rise in U.S. Wage Inequality. *Econometrica*, 90(5), 1973-2016. <https://doi.org/10.3982/ECTA19815>

Albanesi, S., António Dias da Silva, Jimeno, J. F., Lamo, A., & Wabitsch, A. (2023). New Technologies and Jobs in Europe. NBER Working Paper Series. <https://doi.org/10.3386/w31357>

Autor, D. H., & Dorn, D. (2013). The Growth of Low-Skill Service Jobs and the Polarization of the US Labor Market. *The American Economic Review*, 103(5), 1553-1597. <https://doi.org/10.1257/aer.103.5.1553>

Autor, D. H., Levy, F., & Murnane, R. J. (2003). The Skill Content of Recent Technological Change: An Empirical Exploration. *The Quarterly Journal of Economics*, 118(4), 1279-1333.

Bonfiglioli, A., Crinò, R., Gancia, G., & Papadakis, I. (2025). Artificial intelligence and jobs: Evidence from US commuting zones*. *Economic Policy*, 40(121), 145-194. <https://doi.org/10.1093/epolic/eiae059>

Brynjolfsson, E., Mitchell, T., & Rock, D. (2018). What Can Machines Learn and What Does It Mean for Occupations and the Economy? *AEA Papers and Proceedings*, 108, 43-47.

Eurostat. (2025). *Digital economy and society: Comprehensive database* [Data set]. Recuperado el 27 de mayo de 2025, de <https://ec.europa.eu/eurostat/web/digital-economy-and-society/database/comprehensive-database>

Eurostat. (2025). *Employment by sex, age, occupation and economic activity (from 2008 onwards, NACE Rev. 2) (1 000) – lfsa_eisn2* [Data set]. Recuperado el 27 de mayo de 2025, de https://ec.europa.eu/eurostat/databrowser/view/lfsa_eisn2/default/table?lang=en

Eurostat. (2025). *Real GDP per capita – sdg_08_10* [Data set]. Recuperado el 27 de mayo de 2025, de https://ec.europa.eu/eurostat/databrowser/view/sdg_08_10/default/table?lang=en

Eurostat. (2025). *Total unemployment rate – tps00203* [Data set]. Recuperado el 27 de mayo de 2025, de <https://ec.europa.eu/eurostat/databrowser/view/tps00203/default/table?lang=en>

Eurostat. (2025). *Population by educational attainment level, sex, age and labour status (1 000) – edat_lfs_9902* [Data set]. Recuperado el 27 de mayo de 2025, de https://ec.europa.eu/eurostat/databrowser/view/edat_lfs_9902/default/table?lang=en

Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation? *Technological Forecasting and Social Change*, 114, 254-280.
<https://doi.org/10.1016/j.techfore.2016.08.019>

Goos, M., Manning, A., & Salomons, A. (2014). Explaining Job Polarization: Routine-Biased Technological Change and Offshoring. *The American Economic Review*, 104(8), 2509-2526.
<https://doi.org/10.1257/aer.104.8.2509>

Mihaylov, E., & Tijdens, K. G. (2019). Measuring the Routine and Non-Routine Task Content of 427 Four-Digit ISCO-08 Occupations. *SSRN Electronic Journal*.
<https://doi.org/10.2139/ssrn.3389681>

Nedelkoska, L. and G. Quintini (2018), Automation, skills use and training, *OECD Social, Employment and Migration Working Papers*, No. 202, OECD Publishing, Paris. <https://doi.org/10.1787/2e2f4eea-en>

ANEXO

Tabla A1. Resultados completos del modelo sectorial (datos de panel).

PanelOLS Estimation Summary						
Dep. Variable:	Share_Sector	R-squared:	0.8412			
Estimator:	PanelOLS	R-squared (Between):	0.3228			
No. Observations:	644	R-squared (Within):	0.8412			
Date:	Tue, May 20 2025	R-squared (Overall):	0.8347			
Time:	21:34:09	Log-likelihood	1620.7			
Cov. Estimator:	Clustered					
		F-statistic:	119.79			
Entities:	29	P-value	0.0000			
Avg Obs:	22.207	Distribution:	F(26,588)			
Min Obs:	16.000					
Max Obs:	24.000	F-statistic (robust):	2.338e+05			
		P-value	0.0000			
Time periods:	2	Distribution:	F(26,588)			
Avg Obs:	322.00					
Min Obs:	318.00					
Max Obs:	326.00					
Parameter Estimates						
	Parameter	Std. Err.	T-stat	P-value	Lower CI	Upper CI
IA_Adoption	0.2576	0.0775	3.3248	0.0009	0.1054	0.4097
GDPcap	3.693e-08	3.439e-07	0.1074	0.9145	-6.386e-07	7.124e-07
Educ_Rate	-0.0522	0.0276	-1.8897	0.0593	-0.1064	0.0021
Unemp_Rate	-0.0027	0.0542	-0.0502	0.9600	-0.1091	0.1037
C(NACE) [M]	0.0635	0.0170	3.7373	0.0002	0.0301	0.0968
C(NACE) [C]	0.1863	0.0251	7.4141	0.0000	0.1369	0.2356
C(NACE) [D]	0.0269	0.0155	1.7354	0.0832	-0.0035	0.0572
C(NACE) [E]	0.0271	0.0156	1.7420	0.0820	-0.0035	0.0577
C(NACE) [F]	0.0969	0.0160	6.0696	0.0000	0.0656	0.1283
C(NACE) [G]	0.1682	0.0168	10.009	0.0000	0.1352	0.2012
C(NACE) [H]	0.0814	0.0155	5.2481	0.0000	0.0510	0.1119
C(NACE) [I]	0.0637	0.0161	3.9619	0.0001	0.0321	0.0953
C(NACE) [J]	0.0529	0.0159	3.3166	0.0010	0.0216	0.0842
C(NACE) [L]	0.0235	0.0157	1.4926	0.1361	-0.0074	0.0544
C(NACE) [N]	0.0497	0.0165	3.0126	0.0027	0.0173	0.0821
C(NACE) [S]	0.0378	0.0156	2.4233	0.0157	0.0072	0.0685
C(NACE) [T.C]:IA_Adoption	-0.7550	0.4196	-1.7995	0.0725	-1.5790	0.0690
C(NACE) [T.D]:IA_Adoption	-0.2682	0.0768	-3.4924	0.0005	-0.4190	-0.1174
C(NACE) [T.E]:IA_Adoption	-0.2484	0.0886	-2.8026	0.0052	-0.4225	-0.0743
C(NACE) [T.F]:IA_Adoption	-0.6467	0.2517	-2.5691	0.0104	-1.1411	-0.1523
C(NACE) [T.G]:IA_Adoption	-0.7006	0.2422	-2.8927	0.0040	-1.1763	-0.2249
C(NACE) [T.H]:IA_Adoption	-0.5521	0.1515	-3.6443	0.0003	-0.8497	-0.2546
C(NACE) [T.I]:IA_Adoption	-0.0900	0.1518	-0.5929	0.5535	-0.3882	0.2082
C(NACE) [T.J]:IA_Adoption	-0.1601	0.0658	-2.4326	0.0153	-0.2893	-0.0308
C(NACE) [T.L]:IA_Adoption	-0.1149	0.0697	-1.6493	0.0996	-0.2517	0.0219
C(NACE) [T.N]:IA_Adoption	-0.0687	0.0769	-0.8931	0.3721	-0.2197	0.0824
C(NACE) [T.S]:IA_Adoption	-0.1862	0.0746	-2.4972	0.0128	-0.3327	-0.0398

F-test for Poolability: 0.5168

P-value: 0.9839

Distribution: F(29,588)

Included effects: Entity, Time

Tabla A2. Resultados completos del modelo ocupacional (datos de panel).

PanelOLS Estimation Summary						
Dep. Variable:	Share_Occupation	R-squared:	0.2661			
Estimator:	PanelOLS	R-squared (Between):	-5.179e+06			
No. Observations:	6440	R-squared (Within):	0.2661			
Date:	Tue, May 20 2025	R-squared (Overall):	0.2661			
Time:	23:57:13	Log-likelihood	3753.6			
Cov. Estimator:	Clustered					
		F-statistic:	70.064			
Entities:	29	P-value	0.0000			
Avg Obs:	222.07	Distribution:	F(33,6377)			
Min Obs:	160.00					
Max Obs:	240.00	F-statistic (robust):	-2.326e+18			
		P-value	1.0000			
Time periods:	2	Distribution:	F(33,6377)			
Avg Obs:	3220.0					
Min Obs:	3180.0					
Max Obs:	3260.0					
Parameter Estimates						
	Parameter	Std. Err.	T-stat	P-value	Lower CI	Upper CI
IA_Adoption	3.7070	0.3058	12.123	0.0000	3.1076	4.3064
GDPcap	2.758e-18	2.095e-16	0.0132	0.9895	-4.079e-16	4.134e-16
Educ_Rate	5.735e-14	8.543e-12	0.0067	0.9946	-1.669e-11	1.68e-11
Unemp_Rate	4.089e-14	4.486e-12	0.0091	0.9927	-8.752e-12	8.834e-12
C(NACE) [C]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [D]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [E]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [F]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [G]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [H]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [I]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [J]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [L]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [M]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [N]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(NACE) [S]	0.0486	0.0105	4.6335	0.0000	0.0280	0.0691
C(ISCO_08) [T.OC0]	-0.0485	0.0105	-4.6277	0.0000	-0.0691	-0.0280
C(ISCO_08) [T.OC1]	0.0108	0.0105	1.0317	0.3023	-0.0098	0.0314
C(ISCO_08) [T.OC3]	0.1151	0.0149	7.7053	0.0000	0.0858	0.1444
C(ISCO_08) [T.OC4]	0.0453	0.0124	3.6598	0.0003	0.0210	0.0696
C(ISCO_08) [T.OC5]	0.1604	0.0185	8.6784	0.0000	0.1242	0.1967
C(ISCO_08) [T.OC6]	-0.0454	0.0105	-4.3207	0.0000	-0.0659	-0.0248
C(ISCO_08) [T.OC7]	0.1115	0.0174	6.4114	0.0000	0.0774	0.1456
C(ISCO_08) [T.OC8]	0.0759	0.0146	5.1968	0.0000	0.0473	0.1045
C(ISCO_08) [T.OC9]	0.0891	0.0140	6.3768	0.0000	0.0617	0.1165
C(ISCO_08) [T.OC0]:IA_Adoption	-3.7071	0.3058	-12.123	0.0000	-4.3065	-3.1076
C(ISCO_08) [T.OC1]:IA_Adoption	-3.6667	0.2931	-12.511	0.0000	-4.2412	-3.0921
C(ISCO_08) [T.OC3]:IA_Adoption	-3.2168	0.3464	-9.2863	0.0000	-3.8959	-2.5377
C(ISCO_08) [T.OC4]:IA_Adoption	-3.8067	0.3552	-10.717	0.0000	-4.5029	-3.1104
C(ISCO_08) [T.OC5]:IA_Adoption	-5.0329	0.4149	-12.129	0.0000	-5.8462	-4.2195
C(ISCO_08) [T.OC6]:IA_Adoption	-3.7063	0.3064	-12.098	0.0000	-4.3069	-3.1058
C(ISCO_08) [T.OC7]:IA_Adoption	-4.7219	0.4540	-10.402	0.0000	-5.6118	-3.8320
C(ISCO_08) [T.OC8]:IA_Adoption	-4.6392	0.3546	-13.083	0.0000	-5.3343	-3.9441
C(ISCO_08) [T.OC9]:IA_Adoption	-4.5724	0.3500	-13.066	0.0000	-5.2584	-3.8864

F-test for Poolability: 5.318e-14

P-value: 1.0000

Distribution: F(29,6377)

Included effects: Entity, Time

Tabla A3. Resultados completos del modelo con RTI (datos de panel).

PanelOLS Estimation Summary						
Dep. Variable:	Share_Sector	R-squared:		0.0240		
Estimator:	PanelOLS	R-squared (Between):		-0.3278		
No. Observations:	644	R-squared (Within):		0.0239		
Date:	Thu, May 22 2025	R-squared (Overall):		-0.1808		
Time:	19:48:10	Log-likelihood		1036.0		
Cov. Estimator:	Clustered					
		F-statistic:		2.4904		
Entities:	29	P-value		0.0218		
Avg Obs:	22.207	Distribution:		F(6,608)		
Min Obs:	16.000					
Max Obs:	24.000	F-statistic (robust):		5.7286		
		P-value		0.0000		
Time periods:	2	Distribution:		F(6,608)		
Avg Obs:	322.00					
Min Obs:	318.00					
Max Obs:	326.00					
Parameter Estimates						
	Parameter	Std. Err.	T-stat	P-value	Lower CI	Upper CI
IA_Adoption	0.0971	0.2785	0.3485	0.7276	-0.4499	0.6441
Mean_RTI	0.0331	0.0125	2.6573	0.0081	0.0086	0.0576
GDPcap	9.259e-08	5.547e-07	0.1669	0.8675	-9.967e-07	1.182e-06
Educ_Rate	-0.0064	0.0498	-0.1290	0.8974	-0.1041	0.0913
Unemp_Rate	0.0845	0.0788	1.0719	0.2842	-0.0703	0.2393
IA_Adoption:Mean_RTI	0.1467	0.3867	0.3793	0.7046	-0.6127	0.9061

F-test for Poolability: 0.3156

P-value: 0.9998

Distribution: F(29,608)

Included effects: Entity, Time

Tabla A4. Resultados completos del modelo por sub-tareas (datos de panel).

PanelOLS Estimation Summary						
Dep. Variable:	Share_Sector	R-squared:				0.2036
Estimator:	PanelOLS	R-squared (Between):				-30.672
No. Observations:	644	R-squared (Within):				0.2008
Date:	Fri, May 23 2025	R-squared (Overall):				-17.849
Time:	19:59:16	Log-likelihood				1101.5
Cov. Estimator:	Clustered	F-statistic:				12.827
Entities:	29	P-value				0.0000
Avg Obs:	22.207	Distribution:				F(12,602)
Min Obs:	16.000	F-statistic (robust):				21.181
Max Obs:	24.000	P-value				0.0000
Time periods:	2	Distribution:				F(12,602)
Avg Obs:	322.00					
Min Obs:	318.00					
Max Obs:	326.00					
Parameter Estimates						
	Parameter	Std. Err.	T-stat	P-value	Lower CI	Upper CI
IA_Adoption	-1.5088	0.9563	-1.5777	0.1152	-3.3870	0.3693
NRA	0.1630	0.0567	2.8727	0.0042	0.0516	0.2744
NRI	0.7514	0.2306	3.2586	0.0012	0.2986	1.2043
RM	0.5949	0.1597	3.7250	0.0002	0.2812	0.9085
NRM	0.3237	0.0468	6.9092	0.0000	0.2317	0.4157
GDPcap	-5.481e-07	1.311e-06	-0.4180	0.6761	-3.123e-06	2.027e-06
Educ_Rate	0.1303	0.0681	1.9122	0.0563	-0.0035	0.2642
Unemp_Rate	0.1239	0.1167	1.0616	0.2888	-0.1053	0.3531
IA_Adoption:NRA	-1.2431	1.4655	-0.8483	0.3966	-4.1213	1.6350
IA_Adoption:NRI	6.3001	4.4038	1.4306	0.1531	-2.3486	14.949
IA_Adoption:RM	7.6221	3.7066	2.0564	0.0402	0.3427	14.902
IA_Adoption:NRM	0.2166	0.6198	0.3494	0.7269	-1.0007	1.4339

F-test for Poolability: 0.6749

P-value: 0.9023

Distribution: F(29,602)

Included effects: Entity, Time

Tabla A5. Clasificación ISCO-08: grupos principales (OC1-OC9).

ISCO-08	MAJOR-GROUP
OC1	Directores y gerentes
OC2	Profesionales científicos e intelectuales
OC3	Técnicos y profesionales de nivel medio
OC4	Personal de apoyo administrativo
OC5	Trabajadores de los servicios y vendedores de comercios y mercados
OC6	Agricultores y trabajadores calificados agropecuarios, forestales y pesqueros
OC7	Oficiales, operarios y artesanos de artes mecánicas y de otros oficios
OC8	Operadores de instalaciones y máquinas y ensambladores
OC9	Ocupaciones elementales

Fuente: ILO, International Standard Classification of Occupations 2008 (ISCO-08)

Tabla A6. Indicadores de adopción de IA: códigos Eurostat y descripción.

Código Eurostat	Descripción en español
E_DI3_HI_AI_TANY:	Empresas con un alto índice de intensidad digital que utilizan cualquier tecnología de inteligencia artificial.
E_DI3_LO_AI_TANY:	Empresas con un bajo índice de intensidad digital que utilizan cualquier tecnología de inteligencia artificial.
E_DI3_VHI_AI_TANY:	Empresas con un índice de intensidad digital muy alto que utilizan cualquier tecnología de inteligencia artificial.
E_DI3_VLO_AI_TANY:	Empresas con un índice de intensidad digital muy bajo que utilizan cualquier tecnología de inteligencia artificial.
E_DI4_HI_AI_TANY:	Empresas con un alto índice de intensidad digital (Versión 4) que utilizan cualquier tecnología de inteligencia artificial.
E_DI4_LO_AI_TANY:	Empresas con un bajo índice de intensidad digital (Versión 4) que utilizan cualquier tecnología de inteligencia artificial.
E_DI4_VHI_AI_TANY:	Empresas con un índice de intensidad digital muy alto (Versión 4) que utilizan cualquier tecnología de inteligencia artificial.
E_DI4_VLO_AI_TANY:	Empresas con un índice de intensidad digital muy bajo (Versión 4), que utilizan alguna tecnología de inteligencia artificial.

Fuente: Fuente: elaboración propia a partir de Eurostat, Digital Economy and Society Survey 2024

Tabla A7. Proporciones de grupos ocupacionales ISCO-08 (OC1-OC9) por sector NACE, 2023-2024.

ISCO_08 NACE	OC1	OC2	OC3	OC4	OC5	OC6	OC7	OC8	OC9	Total
C	0.06	0.15	0.14	0.07	0.03	0.00	0.28	0.21	0.07	1.0
D	0.03	0.30	0.31	0.11	0.01	0.00	0.21	0.02	0.01	1.0
E	0.02	0.07	0.17	0.09	0.01	0.00	0.10	0.22	0.32	1.0
F	0.06	0.06	0.10	0.04	0.00	0.00	0.56	0.07	0.09	1.0
G	0.08	0.09	0.12	0.09	0.43	0.00	0.10	0.03	0.06	1.0
H	0.05	0.06	0.10	0.19	0.04	0.00	0.03	0.44	0.08	1.0
I	0.09	0.01	0.05	0.06	0.57	0.00	0.01	0.01	0.20	1.0
J	0.08	0.63	0.19	0.06	0.01	0.00	0.02	0.00	0.00	1.0
L	0.08	0.06	0.61	0.10	0.07	0.00	0.02	0.00	0.06	1.0
M	0.07	0.58	0.22	0.09	0.01	0.00	0.02	0.00	0.01	1.0
N	0.05	0.08	0.10	0.13	0.23	0.03	0.03	0.03	0.32	1.0
S	0.04	0.15	0.10	0.05	0.53	0.00	0.06	0.02	0.04	1.0

Fuente: elaboración propia a partir de Eurostat – EU-LFS, 2023-2024.

Tabla A8. Efectos totales de la adopción de IA sobre la participación del empleo por sector NACE (panel 2023-2024).

	Efecto Total	Error estándar	t	p-value
C	-0.497413	0.407065	-1.221948	0.221727
D	-0.010643	0.016146	-0.659189	0.509775
E	0.009163	0.065527	0.139841	0.888786
F	-0.389149	0.229912	-1.692601	0.090532
G	-0.443062	0.212104	-2.088896	0.036717
H	-0.294548	0.130074	-2.264469	0.023545
I	0.167546	0.160355	1.044846	0.296094
J	0.097501	0.042451	2.296792	0.021631
L	0.142658	0.065834	2.166947	0.030239
N	0.188873	0.080707	2.340230	0.019272
S	0.071332	0.024619	2.897401	0.003763

Fuente: elaboración propia a partir de Eurostat (Digital Economy and Society Survey; EU-LFS), 2023-2024.

Tabla A9. Efectos totales de la adopción de IA sobre la participación del empleo por ocupación ISCO-08 (panel 2023-2024).

ISCO	Efecto Total	Error estándar	t	p-value
OC0	-0.000067	0.000541	-0.124804	9.006790e-01
OC1	0.040317	0.053020	0.760409	4.470099e-01
OC2	3.706992	0.305779	12.123127	0.000000e+00
OC3	0.490175	0.142945	3.429129	6.055207e-04
OC4	-0.099665	0.079349	-1.256034	2.091035e-01
OC5	-1.325858	0.185349	-7.153318	8.471002e-13
OC6	0.000644	0.010626	0.060576	9.516969e-01
OC7	-1.014896	0.188188	-5.392982	6.929785e-08
OC8	-0.932223	0.100642	-9.262771	0.000000e+00
OC9	-0.865419	0.088340	-9.796409	0.000000e+00

Fuente: elaboración propia a partir de Eurostat (Digital Economy and Society Survey; EU-LFS), 2023-2024.

Tabla A10. Efectos totales: adopción de IA y participación del empleo sectorial por categoría de tarea (NRA, NRI, RC, RM, NRM), 2023-2024

	Efecto_total	SE	t	p-value
RC	-1.5088	0.9563	-1.5777	0.1146
NRA	-2.7520	2.0720	-1.3282	0.1841
NRI	4.7913	3.5896	1.3348	0.1820
RM	6.1133	2.8184	2.1691	0.0301
NRM	-1.2922	0.8511	-1.5183	0.1289

Fuente: elaboración propia con datos de Eurostat – Digital Economy and Society Survey y EU-LFS, 2023-2024; sub-tareas definidas según Mihaylov y Tijdens (2019).

Clasificación de tareas basada en Mihaylov y Tijdens (2019): NRA (analíticas no rutinarias), NRI (interactivas no rutinarias), RC (cognitivas rutinarias), RM (manuales rutinarias) y NRM (manuales no rutinarias).

Tabla A11. Factores de Inflación de la Varianza (VIF) del modelo sectorial, panel 2023-2024

	Variable	VIF
0	const	81.995129
1	IA_Adoption	14.740148
2	GDP_Cap	2.128643
3	Educ_Rate	1.792428
4	Unemp_Rate	1.142535
5	NACE_C	8.326376
6	NACE_D	5.631709
7	NACE_E	5.524543
8	NACE_F	6.992427
9	NACE_G	7.899199
10	NACE_H	7.715439
11	NACE_I	6.991144
12	NACE_J	10.252530
13	NACE_L	6.551559
14	NACE_N	7.917726
15	NACE_S	4.908736
16	NACE_C_IA	5.570891
17	NACE_D_IA	6.566965
18	NACE_E_IA	2.656118
19	NACE_F_IA	2.781183
20	NACE_G_IA	4.240057
21	NACE_H_IA	3.666605
22	NACE_I_IA	3.044826
23	NACE_J_IA	16.152085
24	NACE_L_IA	3.131546
25	NACE_N_IA	4.844024
26	NACE_S_IA	3.071753

Fuente: elaboración propia a partir de la estimación sectorial (datos Eurostat – Digital Economy and Society Survey & EU-LFS, 2023-2024).

Tabla A12. Factores de Inflación de la Varianza (VIF) del modelo ocupacional, panel 2023-2024

	Variable	VIF
0	const	46.564962
1	IA_Adoption	10.102559
2	GDPCap	1.853157
3	Educ_Rate	1.768007
4	Unemp_Rate	1.128229
5	ISCO_OC0	3.631463
6	ISCO_OC1	3.631463
7	ISCO_OC3	3.631463
8	ISCO_OC4	3.631463
9	ISCO_OC5	3.631463
10	ISCO_OC6	3.631463
11	ISCO_OC7	3.631463
12	ISCO_OC8	3.631463
13	ISCO_OC9	3.631463
14	ISCO_OC0_IA	3.831463
15	ISCO_OC1_IA	3.831463
16	ISCO_OC3_IA	3.831463
17	ISCO_OC4_IA	3.831463
18	ISCO_OC5_IA	3.831463
19	ISCO_OC6_IA	3.831463
20	ISCO_OC7_IA	3.831463
21	ISCO_OC8_IA	3.831463
22	ISCO_OC9_IA	3.831463

Fuente: elaboración propia a partir de la estimación ocupacional (datos Eurostat – Digital Economy and Society Survey & EU-LFS, 2023-2024).

Tabla A13. Test de heterocedasticidad Breusch–Pagan por tipo de panel (sectorial y ocupacional)

Panel	Estadístico BP	p-valor
Sector	215.108	0,000
Ocupacional	731.838	0,000

Fuente: elaboración propia con datos Eurostat – Digital Economy and Society Survey y EU-LFS, 2023-2024.

Tabla A14. Número de observaciones por país en el panel (2023-2024)

	Country	Observations
0	Sweden	24
1	Netherlands	24
2	Poland	24
3	Portugal	24
4	Belgium	24
5	Romania	24
6	Hungary	24
7	Greece	24
8	France	24
9	Serbia	24
10	Slovakia	24
11	Denmark	24
12	Czechia	24
13	Slovenia	24
14	Bulgaria	24
15	Germany	23
16	Croatia	23
17	Norway	22
18	Austria	22
19	Cyprus	22
20	Lithuania	21
21	Latvia	21
22	Ireland	20
23	Estonia	20
24	Spain	20
25	Malta	18
26	Finland	18
27	Italy	18
28	Luxembourg	16

Fuente: elaboración propia a partir de Eurostat – Digital Economy and Society Survey y EU-LFS

Tabla A15. Clasificación NACE Rev. 2 a 1 dígito.

SECCIÓN (1 dígito)	Descripción (título oficial abreviado en español)
A	Agricultura, silvicultura y pesca
B	Industrias extractivas
C	Industria manufacturera
D	Suministro de electricidad, gas, vapor y aire acondicionado
E	Suministro de agua; actividades de saneamiento, gestión de residuos y descontaminación
F	Construcción
G	Comercio al por mayor y al por menor; reparación de vehículos de motor y motocicletas
H	Transporte y almacenamiento
I	Hostelería (alojamiento y servicios de comidas y bebidas)
J	Información y comunicaciones
K	Actividades financieras y de seguros
L	Actividades inmobiliarias
M	Actividades profesionales, científicas y técnicas
N	Actividades administrativas y servicios auxiliares
O	Administración pública y defensa; seguridad social obligatoria
P	Educación
Q	Actividades sanitarias y de servicios sociales
R	Actividades artísticas, recreativas y de entretenimiento
S	Otros servicios personales
T	Actividades de los hogares como empleadores; producción de bienes y servicios para uso propio
U	Actividades de organizaciones y órganos extraterritoriales